


强化学习第四章：动态规划读书笔记

2312167-刘振毫



本章系统讲解了 有限马尔可夫决策过程下的动态规划方法，核心是通过价值函数的迭代更新求解最优策略，是后续所有强化学习算法的理论基础。

一、动态规划概述

核心定位：给定完备 MDP 环境模型，已知状态、动作、收益集合及转移概率 $p(s',r|s,a)$ 时，计算最优策略的优化方法；传统 DP 实用性有限，但为后续近似算法提供核心框架。

核心前提：假设环境为有限 MDP，状态、动作、收益均有限；连续问题可通过量化离散化后使用 DP 求解。

核心思想：用价值函数结构化组织最优策略的搜索，将贝尔曼方程转化为递归更新公式，通过迭代逼近最优价值函数。

二、四大核心基础算法

1. 策略评估（预测）

目标：计算任意给定策略 π 的状态价值函数 v_π ，即预测遵循该策略时每个状态的期望回报。

理论依据：策略的贝尔曼方程

$$\begin{aligned} v_\pi(s) &\doteq \mathbb{E}_\pi[G_t \mid S_t=s] \\ &= \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} \mid S_t=s] \end{aligned} \quad \text{由式 (3.9)}$$

$$= \mathbb{E}_\pi[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t=s] \quad (4.3)$$

$$= \sum_a \pi(a|s) \sum_{s',r} p(s',r|s,a) [r + \gamma v_\pi(s')], \quad (4.4)$$

实现方式：迭代法

双数组更新：分别存储新旧价值函数，同步更新所有状态。

就地更新：单数组直接覆盖旧值，新值可立即被后续计算使用，收

敛更快，是 DP 算法的默认实现。

终止条件：所有状态价值的最大变化量 $\Delta < \theta$ (θ 为预设精度阈值)；终止状态价值恒为 0。

示例：4×4 网格问题，等概率随机策略下，价值函数收敛为各状态到终止状态的期望步数的负值。

2. 策略改进

目标：基于当前策略的价值函数，构造一个更优的新策略。

核心依据：策略改进定理

若对任意状态 s ，有 $q\pi(s, \pi'(s)) \geq v\pi(s)$ ，则策略 π' 不劣于 π ；若存在至少一个状态使不等式严格成立，则 π' 严格更优。

实现方法：贪心策略构造

$$\begin{aligned}\pi'(s) &\doteq \operatorname{argmax}_a q_\pi(s, a) \\ &= \operatorname{argmax}_a \mathbb{E}[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s, A_t = a] \\ &= \operatorname{argmax}_a \sum_{s', r} p(s', r \mid s, a) [r + \gamma v_\pi(s')],\end{aligned}\tag{4.9}$$

即每个状态选择能最大化单步期望回报的动作。

收敛性：若贪心策略与原策略完全一致，则当前策略满足贝尔曼最优方程，即为最优策略。

扩展：支持随机策略，多个动作取得相同最大值时，可给最优动作分配任意非零概率。

3. 策略迭代

核心流程：交替执行策略评估和策略改进，形成闭环迭代

$\pi_0 \rightarrow \text{评估 } v_{\pi_0} \rightarrow \text{改进 } \pi_1 \rightarrow \text{评估 } v_{\pi_1} \rightarrow \text{改进} \dots \rightarrow \pi^*, v^*$

特点：每次策略评估需迭代到收敛，再进行策略改进；有限 MDP 下，策略总数有限，算法必然在有限次迭代后收敛到最优。

示例：杰克租车问题，初始策略为不移动车辆，经多次迭代得到最优车辆调度策略。

不足：每次策略评估需多次遍历整个状态集，计算开销大。

4. 价值迭代

核心思想：截断策略评估，仅对状态集进行一次遍历就执行策略改进，将评估与改进步骤合并为单步更新。

更新公式：贝尔曼最优方程的迭代形式

$$\begin{aligned} v_{k+1}(s) &\doteq \max_a \mathbb{E}[R_{t+1} + \gamma v_k(S_{t+1}) \mid S_t = s, A_t = a] \\ &= \max_a \sum_{s', r} p(s', r \mid s, a) [r + \gamma v_k(s')] \end{aligned} \quad (4.10)$$

终止条件：同策略评估，价值函数最大变化量小于阈值；最终通过贪心策略从最优价值函数导出最优策略。

特点：大幅减少迭代次数，收敛速度远快于策略迭代；示例：赌徒问题，求解最大化获胜概率的最优下注策略。

三、异步动态规划

解决痛点：同步 DP 需遍历整个状态集，面对大规模状态空间时计算不可行。

核心特性：不系统遍历状态集，以任意顺序更新状态值；只要保证所有状态被无限次更新，算法仍能收敛到最优。

优势：

可聚焦于与最优轨迹相关的状态，跳过无关状态；

支持实时交互：智能体实际访问状态时再更新其价值，实现计算与决策并行。

四、广义策略迭代（GPI）

定义：策略评估与策略改进相互作用的通用框架，与两个流程的粒度、执行顺序无关。

核心逻辑：两个流程既竞争又合作

评估流程：使价值函数匹配当前策略；

改进流程：使策略贪心于当前价值函数；

最终两者同时稳定，收敛到最优价值函数和最优策略。

意义：几乎所有强化学习算法都可被描述为 GPI，是理解强化学习本质的核心视角。

五、动态规划的效率与局限

效率优势

最坏情况下时间复杂度为状态数 n 和动作数 k 的多项式级，指数优于直接穷举策略空间，策略总数为 kn ；

现代计算机可解决拥有数百万状态的 MDP 问题；

初始价值、策略较好时，收敛速度远快于理论最坏情况。

核心局限

需已知转移概率，而实际问题中该条件通常不满足；

维度灾难：状态数随状态变量的增加呈指数级增长。

应对方案：采用异步 DP，聚焦于高价值状态的更新；结合近似方法。

六、总结

DP 的核心操作是期望更新：基于所有后继状态的价值和转移概率，更新当前状态的价值，本质是将贝尔曼方程转化为赋值语句。

自举法思想基于其他状态的价值估计来更新当前状态的价值估计。

策略迭代和价值迭代是 DP 的两大主流算法，为后续无模型强化学习算法奠定了理论基础。