

强化学习原理：多臂赌博机与有限马尔科夫决策过程

郭宪

2025.02.25


人工智能学院

College of Artificial Intelligence



南开大学
Nankai University

强化学习极其简单的例子：多臂赌博机



多臂赌博机：

K 个臂

摇动每个臂时，得到不同概略分布的回报


目的：

如何摇动 N 次得到最高的回报

问题：

如何通过学习知道，摇哪个臂能得到最好的回报

强化学习极其简单的例子：多臂赌博机



动作： $a = [0, 1, 2]$

立即回报： r ，服从三个不同的回报

状态： s

目标：在状态 s ，最优的动作

定义动作的值： $q_*(a) = E[R_t | A_t = a]$

强化学习：利用回报 r 学习最优的动作，**学习动作的评估**

$$s \xrightarrow[r=0.2]{a=0} s_T$$


$$s \xrightarrow[r=0.3]{a=1} s_T$$

$$s \xrightarrow[r=0.6]{a=2} s_T$$

定义 **每个动作的估计值**：

$$Q(a) = \frac{\sum_{i=1}^{t-1} R_i \cdot \mathbb{I}_{A_i=a}}{\sum_{i=1}^{t-1} \mathbb{I}_{A_i=a}}$$

强化学习极其简单的例子：多臂赌博机



$$s \xrightarrow[r=0.2]{a=0} s_T, q[0] = 0.2$$

$$s \xrightarrow[r=0.3]{a=1} s_T, q[1] = 0.3$$

$$s \xrightarrow[r=0.6]{a=2} s_T, q[2] = 0.6$$

在每个杆都试过一次后，你如何选下一个杆？

利用当前的知识


贪婪策略： $a = \arg \max_a q(a)$ exploitation

选择非贪婪动作 exploration

探索-利用平衡策略 与环境进行交互：

$$\varepsilon - greedy: a = \begin{cases} \arg \max_a q(a) & \text{with probability } 1 - \varepsilon \\ a \text{ random action} & \text{with probability } \varepsilon \end{cases}$$

强化学习极其简单的例子：多臂赌博机



增量式计算：

$$\begin{aligned}
 Q_{n+1} &= \frac{1}{n} \sum_{i=1}^n R_i \\
 &= \frac{1}{n} \left(R_n + \sum_{i=1}^{n-1} R_i \right) \\
 &= \frac{1}{n} \left(R_n + (n-1) \frac{1}{n-1} \sum_{i=1}^{n-1} R_i \right) \\
 &= \frac{1}{n} (R_n + (n-1)Q_n) \\
 &= \frac{1}{n} (R_n + nQ_n - Q_n) \\
 &= Q_n + \frac{1}{n} [R_n - Q_n]
 \end{aligned}$$

A simple bandit algorithm

Initialize, for $a = 1$ to k :

$$Q(a) \leftarrow 0$$

$$N(a) \leftarrow 0$$

Loop forever:

$$A \leftarrow \begin{cases} \operatorname{argmax}_a Q(a) & \text{with probability } 1 - \varepsilon \quad (\text{breaking ties randomly}) \\ \text{a random action} & \text{with probability } \varepsilon \end{cases}$$

$$R \leftarrow \text{bandit}(A)$$

$$N(A) \leftarrow N(A) + 1$$

$$Q(A) \leftarrow Q(A) + \frac{1}{N(A)} [R - Q(A)]$$

强化学习极其简单的例子：多臂赌博机

A simple bandit algorithm

Initialize, for $a = 1$ to k :

$Q(a) \leftarrow 0$

$N(a) \leftarrow 0$



Loop forever:

$A \leftarrow \begin{cases} \operatorname{argmax}_a Q(a) & \text{with probability } 1 - \varepsilon \quad (\text{breaking ties randomly}) \\ \text{a random action} & \text{with probability } \varepsilon \end{cases}$

$R \leftarrow \text{bandit}(A)$

$N(A) \leftarrow N(A) + 1$

$Q(A) \leftarrow Q(A) + \frac{1}{N(A)} [R - Q(A)]$



所有强化学习算法包括且只包括两个过程：

采集数据： 利用探索-利用平衡策略进行采集数据



动作评估

学习： 利用采集到的数据**优化当前策略**



强化学习极其简单的例子：多臂赌博机



Upper-Confidence-Bound 动作选择

$$A_t = \arg \max_a [Q_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}}]$$




不确定性的度量

玻尔兹曼分布：动作选择

$$\Pr\{A_t = a\} \doteq \frac{e^{H_t(a)}}{\sum_{b=1}^k e^{H_t(b)}} \doteq \pi_t(a)$$

强化学习极其简单的例子：多臂赌博机



A simple bandit algorithm

Initialize, for $a = 1$ to k :

$$Q(a) \leftarrow 0$$

$$N(a) \leftarrow 0$$

Loop forever:


$$A \leftarrow \begin{cases} \operatorname{argmax}_a Q(a) & \text{with probability } 1 - \varepsilon \quad (\text{breaking ties randomly}) \\ \text{a random action} & \text{with probability } \varepsilon \end{cases}$$

$$R \leftarrow \text{bandit}(A)$$

$$N(A) \leftarrow N(A) + 1$$


$$Q(A) \leftarrow Q(A) + \frac{1}{N(A)} [R - Q(A)]$$

Figure 1





多臂赌博机的学习曲线


从多臂赌博机到马尔科夫决策过程




单状态





多状态



从多臂赌博机到马尔科夫决策过程




单状态



$$S \xrightarrow{a} r, S$$



多臂赌博机

从多臂赌博机到马尔科夫决策过程



多状态


动作不仅仅影响回报还影响状态的转移




$$s_t \xrightarrow{a_t} r_t, s_{t+1}$$

马尔科夫决策过程

从多臂赌博机到马尔科夫决策过程



机器人找金币



多臂赌博机

延迟回报 (delayed reward) : $1 \xrightarrow{e} 2 \xrightarrow{e} 3 \xrightarrow{s} 7(\text{reward})$

评价该动作：立即回报 和 将来回报 的平衡问题

立即回报来评价该动作

在马尔科夫决策过程问题中，我们要评估每个状态处的动作值函数： $q(s,a)$

只评价当前状态的动作

如何评估？

马尔科夫决策过程


马尔科夫决策过程描述交互过程

Agent: 智能体

Environment: 环境

智能体与环境进行序贯交互：
trajectory(轨迹)

$S_0, A_0, R_1, S_1, A_1, R_2, S_2, A_2, R_3, \dots$



智能体与环境交互

如果将状态 S_t 和回报 R_t 视为随机变量，那么该轨迹可以用一个随机过程来描述

随机变量，条件概率，分布，期望，方差，随机过程，马尔科夫过程的概念



概率论基础

1. 随机变量:

随机变量是指可以随机地取不同值的变量

2. 概率分布:

概率分布用来描述随机变量在每个可能取到的值处的可能性大小

3. 期望和方差:

离散型:
$$E_{x \sim P}[f(x)] = \sum_x P(x) f(x)$$

连续型:
$$E_{x \sim P}[f(x)] = \int p(x) f(x) dx$$

方差:
$$\text{Var}(f(x)) = E[(f(x) - E[f(x)])^2]$$



概率论基础



条件概率：

事件A已经发生的条件下，事件B发生的概率： $P(B | A)$

随机过程：

设 (Ω, Σ, P) 是一概率空间，对每一个参数 $t \in T$ ， $X(t, \omega)$ 是定义在概率空间 (Ω, Σ, P) 上的随机变量

则称随机变量族 $X_T = \{X(t, \omega); t \in T\}$ 为该概率空间上的一随机过程。 “中科院 孙应飞 随机过程”

马尔科夫过程：

状态满足马尔科夫性的随机过程称为马尔科夫过程



马尔科夫性

马尔科夫性： 系统的下一个状态只与当前状态有关，与以前状态无关。

定义： 一个状态 S_t 是马尔科夫的，当且仅当：


$$P[S_{t+1}|S_t] = P[S_{t+1}|S_1, \dots, S_t]$$

1. 当前状态蕴含所有相关的历史信息
2. 一旦当前状态已知，历史信息将会被抛弃

马尔科夫决策过程 (MDP)

MDP: 带有决策和回报的马尔科夫过程:

定义: 马尔科夫决策过程由元组: (S, A, P, R, γ) 描述
 S 为有限的状态集, A 为有限的行为集, P 为状态转移概率, **R 为回报函数**, γ 为折扣因子



随机变量 s', r 的分布由条件概率定义:

$$p(s', r | s, a) \doteq \Pr\{S_t = s', R_t = r | S_{t-1} = s, A_{t-1} = a\}$$

该条件概率描述了交互的动力学, 是对状态的限制。

状态转移概率:

$$p(s' | s, a) \doteq \sum_{r \in R} p(s', r | s, a)$$

回报的期望:

$$r(s, a) \doteq E[R_t | S_{t-1} = s, A_{t-1} = a] = \sum_{r \in R} r \sum_{s' \in S} p(s', r | s, a)$$



马尔科夫决策过程：状态

马尔科夫决策过程是一种很概括和抽象的框架，很多问题都可以建模为马尔科夫决策过程

S 为有限的状态集。

状态：可以是任意我们能够知道的可能有助于做决策的量

DQN 的状态为连续的四帧图像

AlphaGo 的状态为过去八手的双方棋局

The exact architecture, shown schematically in Fig. 1, is as follows. The input to the neural network consists of an $84 \times 84 \times 4$ image produced by the preprocessing map ϕ . The first hidden layer convolves 32 filters of 8×8 with stride 4 with the

Neural network architecture. The input to the neural network is a $19 \times 19 \times 17$ image stack comprising 17 binary feature planes. Eight feature planes, X_t , consist of binary values indicating the presence of the current player's stones ($X_t^i = 1$ if intersection i contains a stone of the player's colour at time-step t ; 0 if the intersection is empty, contains an opponent stone, or if $t < 0$). A further 8 feature planes, Y_t , represent the corresponding features for the opponent's stones. The final feature plane, C , represents the colour to play, and has a constant value of either 1 if black is to play or 0 if white is to play. These planes are concatenated together to give input features $s_t = [X_t, Y_t, X_{t-1}, Y_{t-1}, \dots, X_{t-7}, Y_{t-7}, C]$. History features X_t, Y_t are

状态的表示会严重影响学习效果，状态的表示目前还是一门艺术，而非科学。

本质的问题：三个信号在往前传播和往后传播：状态，动作和回报



马尔科夫决策过程：动作

马尔科夫决策过程是一种很概括和抽象的框架，很多问题都可以建模为马尔科夫决策过程

A为有限的行为集：

动作：任何我们想要学习的需要做的决定

包括宏观动作、微观动作、精神层面的，物质层面的

机器人学习走路：动作可以是关节力矩，还可以是关节角度，甚至可以是电机的电压。

本质的问题：三个信号在往前传播和往后传播：状态，动作和回报


马尔科夫决策过程 (MDP)

定义：马尔科夫决策过程是元组： (S, A, P, R, γ)

一个马尔科夫决策过程（很长的交互）：

$$s(1) \xrightarrow[r=0]{a='e'} s(2) \xrightarrow[r=0]{a='e'} s(3) \xrightarrow[r=1]{a='s'} s_T$$

$$s(1) \xrightarrow[r=0]{a='e'} s(2) \xrightarrow[r=0]{a='e'} s(3) \xrightarrow[r=0]{a='e'} s(4) \xrightarrow[r=0]{a='e'} s(5) \xrightarrow[r=-1]{a='s'} s_T$$



在马尔科夫决策过程，智能体学习的目的是最大化总回报



马尔科夫决策过程：立即回报



立即回报的设置：智能体最大化累积回报的时候可以实现我们的最终目标

机器人学习走路：立即回报正比于前向运动的速度

机器人逃离迷宫：每走一步给 -1 以鼓励它尽快逃离迷宫

下棋：赢给 $+1$ ， 输给 -1 ， 平局给 0

智能体的目标：最大化**累积回报**

马尔科夫决策过程：累积回报

智能体的目标：最大化**累积回报**

如何定义**累积回报**？


$$s(1) \xrightarrow[r=0]{a='e'} s(2) \xrightarrow[r=0]{a='e'} s(3) \xrightarrow[r=1]{a='s'} s_T$$

回报 (return) : $G_t \doteq R_{t+1} + R_{t+2} + \dots + R_T$

幕 (episodes) : 一次交互序列

终止状态 (terminal state) : 终止状态

episodic tasks: 带有终止状态的任务



continuing tasks: 没有终止状态的，连续进行的任务。如过程控制，机器人运动

马尔科夫决策过程：折扣累积回报

智能体的目标：最大化**累积回报**

如何定义**累积回报**？


折扣回报 (discounted return) :

$$G_t \doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$$

γ 称为折扣率，并且 $0 \leq \gamma \leq 1$

$\gamma=0$: 智能体是短视的 (myopic)，最大化立即回报

γ 接近1，说明智能体是有远见的 (farsighted)，考虑将来的回报



$$G_t \leq \frac{1}{1-\gamma} \max R_t$$

马尔科夫决策过程：值函数与策略

$$s(1) \xrightarrow[r=0]{a='e'} s(2) \xrightarrow[r=0]{a='e'} s(3) \xrightarrow[r=1]{a='s'} s_T$$

$$G_t \doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$$


状态s的好坏：值函数 $v(s)$ (状态的函数)。

值函数跟策略有关，不同的策略对应不同的值函数

策略的定义：

一个策略 π 是给定状态s时，动作集上的一个分布：

$$\pi(a|s) = p[A_t = a | S_t = s]$$





马尔科夫决策过程：策略的定义



一个策略 π 是给定状态 s 时，动作集上的一个分布：

$$A = \{ 'e', 's', 'w', 'n' \}$$

1. 贪婪策略：

$$\pi_*(a | s) = \begin{cases} 1 & \text{if } a = \arg \max_{a \in A} q_*(s, a) \\ 0 & \text{otherwise} \end{cases}$$

2. ε - greedy 策略：

$$\pi(a|s) \leftarrow \begin{cases} 1 - \varepsilon + \frac{\varepsilon}{|A(s)|} & \text{if } a = \arg \max_a Q(s, a) \\ \frac{\varepsilon}{|A(s)|} & \text{if } a \neq \arg \max_a Q(s, a) \end{cases}$$

状态集： $S = \{1, 2, 3, 4, 5, 6, 7, 8\}$

动作集： $A = \{ 'e', 's', 'w', 'n' \}$

R为立即回报



常用策略举例



3. 高斯策略: $\pi_{\theta} = \mu_{\theta} + \varepsilon, \varepsilon \sim N(0, \sigma^2)$

4. 玻尔兹曼分布:


$$\pi_{\theta}(a | s) = \frac{\exp(Q(s, a; \theta))}{\sum_b \exp(Q(s, b; \theta))}$$

马尔科夫决策过程：值函数定义

给定markov链：

$$s(1) \xrightarrow[r=0]{a='e'} s(2) \xrightarrow[r=0]{a='e'} s(3) \xrightarrow[r=1]{a='s'} s_T$$

$$s(1) \xrightarrow[r=0]{a='e'} s(2) \xrightarrow[r=0]{a='e'} s(3) \xrightarrow[r=0]{a='e'} s(4) \xrightarrow[r=0]{a='e'} s(5) \xrightarrow[r=-1]{a='s'} s_T$$



可分别计算累积回报

$$G_t(s) \doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$$

由于状态转移概率和策略的随机性，因此折扣累积回报 $G(s)$ 是随机变量。

值函数的定义：在策略 π 下，状态 s 的值函数定义为从状态 s 出发，并采用策略 π 的折扣积累回报的期望。

$$v_{\pi}(s) \doteq E_{\pi}[G_t | S_t = s] = E_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s\right], \text{ for all } s \in S$$



马尔科夫决策过程：值函数定义


值函数的定义：在策略 π 下，状态 s 的值函数定义为从状态 S 出发，并采用策略 π 的折扣积累回报的期望。

$$v_{\pi}(s) \doteq E_{\pi} [G_t | S_t = s] = E_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s \right], \text{ for all } s \in S$$

行为值函数的定义：在策略 π 下，在状态 s ，并采取动作 a 的行为值函数定义为，从状态 S 出发，采用动作 a 与环境交互，之后采用策略 π 所得到的折扣积累回报的期望。

$$q_{\pi}(s, a) \doteq E_{\pi} [G_t | S_t = s, A_t = a] = E_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s, A_t = a \right], \text{ for all } s \in S$$

马尔科夫决策过程：贝尔曼方程




值函数的贝尔曼方程


$$v_{\pi}(s) = \sum_{a \in A} \pi(a|s) \left(R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_{\pi}(s') \right)$$

回溯：backup计算值函数

后继状态：s'



值函数的具体形式理解



状态集: $S = \{s_1, s_2, s_3, s_4, s_5\}$

动作集: $A = \{\text{玩, 退出, 学习, 发论文, 睡觉}\}$

R为立即回报 $\pi(a|s) = 0.5, \gamma = 1$

$$v_{\pi}(s) = \sum_{a \in A} \pi(a|s) q_{\pi}(s, a)$$

$$q_{\pi}(s, a) = R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_{\pi}(s')$$

$$v_{\pi}(s) = \sum_{a \in A} \pi(a|s) \left(R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_{\pi}(s') \right)$$

$$q_{\pi}(s, a) = R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a \sum_{a' \in A} \pi(a'|s') q_{\pi}(s', a')$$

$$7.4 = 0.5(1 + 0.2 * (-1.3) + 0.4 * 2.7 + 0.4 * 7.4) + 0.5 * 10$$


最优价值函数和最优状态-动作价值函数

最优状态价值函数是指 $v^*(s)$ 在**所有策略**中值最大的值函数，即： $v^*(s) = \max_{\pi} v_{\pi}(s)$

最优状态-动作价值函数是指 $q^*(s, a)$ 在**所有策略**中值最大的值函数，即： $q^*(s, a) = \max_{\pi} q_{\pi}(s, a)$

$$v_{\pi}(s) = \sum_{a \in A} \pi(a|s) q_{\pi}(s, a)$$

$$q_{\pi}(s, a) = R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_{\pi}(s')$$



$$v_{\pi}(s) = \sum_{a \in A} \pi(a|s) \left(R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_{\pi}(s') \right)$$


$$q_{\pi}(s, a) = R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a \sum_{a' \in A} \pi(a'|s') q_{\pi}(s', a')$$

贝尔曼最优化方程：

$$v^*(s) = \max_a R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_*(s')$$

$$q^*(s, a) = R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a \max_{a'} q^*(s', a')$$

最优策略



$$v^*(s) = \max_a R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_*(s')$$

若已知最优动作价值函数，最优策略可以通过直接最大化 $q_*(s, a)$ 来决定。


$$\pi_*(a|s) = \begin{cases} 1 & \text{if } a = \operatorname{argmax}_{a \in A} q_*(s, a) \\ 0 & \text{otherwise} \end{cases}$$

状态集: $S = \{s_1, s_2, s_3, s_4, s_5\}$

动作集: $A = \{\text{玩}, \text{退出}, \text{学习}, \text{发论文}, \text{睡觉}\}$

R为立即回报

强化学习的形式化表示



马尔科夫决策问题 (MDP) : 四元组 (S, A, P, r)

策略: $\pi: S \rightarrow u$ 。常采用随机策略: $\pi(u|s)$

累积回报: $R(\tau) = r_T(x_T) + \sum_{t=0}^{T-1} r_t(x_t, u_t)$

折扣回报: $R = \sum_{t=0}^{\infty} \gamma^t r_t$

强化学习目标: $\max_{\pi} \int R(\tau) p_{\pi}(\tau) d\tau$

值函数

值函数最优时采取的策略是最优的, 反过来, 策略最优时, 值函数最优。



第二次作业



1. 阅读 Sutton 书第1章， 并做读书笔记