

强化学习原理

2025.03.18

人工智能学院

College of Artificial Intelligence



南开大学
Nankai University

TD学习是**采样更新**: ← 一个样本


$$V(S_t) \leftarrow V(S_t) + \alpha (R_{t+1} + \gamma V(S_{t+1}) - V(S_t))$$

DP学习是**期望更新**: ← 先计算期望

$$v_{\pi}(s) = \sum_{a \in A} \pi(a|s) \left(R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_{\pi}(s') \right)$$

TD偏差, 新的估计值与旧的估计值的差:

$$\delta_t = R_{t+1} + \gamma v(s_{t+1}) - v(s_t)$$



DP, MC and TD

DP方法估计值函数：


$$v_{l+1}(s) = \max_a R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_l(s')$$

MC方法估计值函数：

$$v(s_t) = \mathbb{E}_{\pi} (r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots)$$

时间差分的方法评估值函数：

$$v(s_t) = \mathbb{E}_{\pi} (r_{t+1} + \gamma v(s_{t+1}))$$



DP, MC and TD

MC: 利用采样平均回报逼近期望

$$\begin{aligned} v_{\pi}(s) &= E_{\pi}[G_t | S_t = s] \\ &= E_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s\right] \\ &= E_{\pi}\left[R_{t+1} + \gamma \sum_{k=0}^{\infty} \gamma^k R_{t+k+2} | S_t = s\right] \\ &= E_{\pi}\left[R_{t+1} + \gamma v_{\pi}(S_{t+1}) | S_t = s\right] \end{aligned}$$

TD: 联合了MC和DP, 采样期望值, 并利用真值的当前估计值 $V(S_{t+1})$

DP: 期望值由模型来提供, 但是利用真值的当前估计值 $V(S_{t+1})$

MC and TD 偏差与方差平衡

增量式MC方法估计值函数：

$$V(S_t) \leftarrow V(S_t) + \alpha (G_t - V(S_t))$$

$$G_t = R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{T-1} R_T$$

最简单的时间差分学习算法：TD(0)

$$V(S_t) \leftarrow V(S_t) + \alpha (R_{t+1} + \gamma V(S_{t+1}) - V(S_t))$$

$R_{t+1} + \gamma V(S_{t+1})$ 称为TD目标

$\Rightarrow G_t$ 是值函数 $v_\pi(S_t)$ 的无偏估计

$\Rightarrow$ 真实的TD目标 $R_{t+1} + \gamma v_\pi(S_{t+1})$ 是无偏估计，
但 $R_{t+1} + \gamma V(S_{t+1})$ 是有偏估计

TD目标 $R_{t+1} + \gamma v_\pi(S_{t+1})$ 的方差比MC的返回值 G_t 要小很多。因为MC的返回值依赖于很多随机动作，转移概率和回报。TD目标仅依赖于一个随机动作，转移概率和回报。



时间差分学习的优势

TD学习是采样更新:

$$V(S_t) \leftarrow V(S_t) + \alpha (R_{t+1} + \gamma V(S_{t+1}) - V(S_t))$$

DP学习是期望更新:

$$v_{\pi}(s) = \sum_{a \in A} \pi(a|s) \left(R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_{\pi}(s') \right)$$

(1) TD不需要环境模型, 回报函数模型, 下一个状态的概率分布


(2) 跟MC相比, TD只需要等待一个时间步。

(3) TD只评估当前的动作, 与后继动作没关系。

TD方法收敛已经证明

Sarsa: On-Policy TD

学习行为值函数:




$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[r_{t+1} + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)]$$

最基本的数据单元:

$$(s_t, a_t, r_t, s_{t+1}, a_{t+1})$$

这种学习方法称为: Sarsa





Sarsa: On-Policy TD

1. 初始化 $Q(s, a), \forall s \in S, a \in A(s)$, 给定参数 α, γ

2. Repeat:

行动策略和评估策略都是 ϵ 贪婪策略

给定起始状态 s , 并根据 ϵ 贪婪策略在状态 s 选择动作 a

Repeat (对于一幕的每一步)

(a) 根据 ϵ 贪婪策略在状态 s 选择动作 a , 得到回报 r 和下一个状态 s' , 在状态 s'

根据 ϵ 贪婪策略得到动作 a'

(b) $Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma Q(s', a') - Q(s, a)]$

(c) $s = s', a = a'$


Until s 是终止状态

Until 所有的 $Q(s, a)$ 收敛

3. 输出最终策略: $\pi(s) = \operatorname{argmax}_a Q(s, a)$

Qlearning: Off-policy TD

学习行为值函数:




$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_{t+1} + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t) \right]$$

最基本的数据单元:

$$(s_t, a_t, r_t, s_{t+1})$$

学到的行为值函数直接逼近最优行为值函数: $q_*(s, a)$





Qlearning: Off-policy TD

1. 初始化 $Q(s, a), \forall s \in S, a \in A(s)$, 给定参数 α, γ

2. Repeat:

给定起始状态 s , 并根据 $\mathcal{E}$ 贪婪策略在状态 s 选择动作 a

Repeat (对于一幕的每一步)

(a) 根据 $\mathcal{E}$ 贪婪策略在状态 s_t 选择动作 a_t , 得到回报 r_t 和下一个状态 s_{t+1}

(b) $Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha [r_t + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t)]$

(c) $s = s', a = a'$

Until s 是终止状态


Until 所有的 $Q(s, a)$ 收敛

3. 输出最终策略: $\pi(s) = \underset{a}{\operatorname{argmax}} Q(s, a)$

行动策略为 $\mathcal{E}$ 贪婪策略


目标策略为贪婪策略

学习行为值函数：



$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha [r_{t+1} + \gamma \mathbb{E}_\pi Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)]$$

$$\leftarrow Q(s_t, a_t) + \alpha \left[r_{t+1} + \gamma \sum_a \pi(a|s_{t+1}) Q(s_{t+1}, a) - Q(s_t, a_t) \right]$$



学到的行为值函数直接逼近期望行为值函数

跟sarsa相比，消除了由于策略的随机而带来的方差

Double Qlearning


Qlearning更新:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_{t+1} + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t) \right]$$

最优化操作, 容易导致偏差, 称为**最大化偏差**

Double-Qlearning 更新:

$$Q_1(s_t, a_t) \leftarrow Q_1(s_t, a_t) + \alpha \left[r_{t+1} + \gamma Q_2(s_{t+1}, \arg \max_a Q_1(s_{t+1}, a)) - Q_1(s_t, a_t) \right]$$





Double Qlearning

Double Q-learning, for estimating $Q_1 \approx Q_2 \approx q_*$

Algorithm parameters: step size $\alpha \in (0, 1]$, small $\varepsilon > 0$

Initialize $Q_1(s, a)$ and $Q_2(s, a)$, for all $s \in \mathcal{S}^+, a \in \mathcal{A}(s)$, such that $Q(\text{terminal}, \cdot) = 0$

Loop for each episode:

Initialize S

Loop for each step of episode:

Choose A from S using the policy ε -greedy in $Q_1 + Q_2$

Take action A , observe R, S'

With 0.5 probability:


$$Q_1(S, A) \leftarrow Q_1(S, A) + \alpha \left(R + \gamma Q_2(S', \arg \max_a Q_1(S', a)) - Q_1(S, A) \right)$$

else:

$$Q_2(S, A) \leftarrow Q_2(S, A) + \alpha \left(R + \gamma Q_1(S', \arg \max_a Q_2(S', a)) - Q_2(S, A) \right)$$

$S \leftarrow S'$

until S is terminal



表格型强化学习算法

动态规划值函数迭代算法

输入：状态转移概率 $P_{ss'}^a$, 回报函数 R_s^a , 折扣因子 γ

初始化值函数: $v(s) = 0$ 初始化策略 π_0

Repeat $l=0,1,\dots$

for **every** s do

$$v_{l+1}(s) = \max_a R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_l(s')$$

Until $v_{l+1} = v_l$

输出: $\pi(s) = \operatorname{argmax}_a R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_l(s')$

[1] 初始化所有: $s \in S, a \in A(s), Q(s, a) \leftarrow \text{arbitrary}$

$\text{Returns}(s, a) \leftarrow \text{empty list}$

$\pi(s) \leftarrow \text{arbitrary } \varepsilon\text{-soft 策略,}$

Repeat:

[2] 从 S_0, A_0 开始以策略 π 生成一次实验 (episode),

[3] 对**每对**在这个实验中出现的状态和动作, s, a :

$G \leftarrow s, a$ 第一次出现后的回报

将G附加于回报 $\text{Returns}(s, a)$ 上


策略评估

$Q(s, a) \leftarrow \text{average}(\text{Returns}(s, a))$ 对回报取均值

[4] 对该实验中的每一个 s :

策略改进

$$\pi(a|s) \leftarrow \begin{cases} 1 - \varepsilon + \frac{\varepsilon}{|A(s)|} & \text{if } a = \arg \max_a Q(s, a) \\ \frac{\varepsilon}{|A(s)|} & \text{if } a \neq \arg \max_a Q(s, a) \end{cases}$$



Sarsa: On-Policy TD

1. 初始化 $Q(s,a), \forall s \in S, a \in A(s)$, 给定参数 α, γ

2. Repeat:

行动策略和评估策略都是 ϵ 贪婪策略

给定起始状态 s , 并根据 ϵ 贪婪策略在状态 s 选择动作 a

Repeat (对于一幕的每一步)

(a) 根据 ϵ 贪婪策略在状态 s 选择动作 a , 得到回报 r 和下一个状态 s' , 在状态 s' 根据 ϵ 贪婪策略得到动作 a'


(b) $Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma Q(s',a') - Q(s,a)]$

(c) $s=s', a=a'$

Until s 是终止状态

Until 所有的 $Q(s,a)$ 收敛

3. 输出最终策略: $\pi(s) = \arg \max_a Q(s,a)$



Qlearning: Off-policy TD

1. 初始化 $Q(s, a), \forall s \in S, a \in A(s)$, 给定参数 α, γ

2. Repeat:

给定起始状态 s , 并根据 $\mathcal{E}$ 贪婪策略在状态 s 选择动作 a

Repeat (对于一幕的每一步)

(a) 根据 $\mathcal{E}$ 贪婪策略在状态 s_t 选择动作 a_t , 得到回报 r_t 和下一个状态 s_{t+1}

(b) $Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha [r_t + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t)]$

(c) $s = s', a = a'$

Until s 是终止状态

Until 所有的 $Q(s, a)$ 收敛


3. 输出最终策略: $\pi(s) = \underset{a}{\operatorname{argmax}} Q(s, a)$

行动策略为 $\mathcal{E}$ 贪婪策略

目标策略为贪婪策略

值函数的表示


$q(s, a)$



行为值函数的数目： $|S| \cdot |A|$

大的MDP问题：状态空间连续或状态数无穷多


1. 存储空间无穷大
2. 学习速度很慢



状态空间表示为：图像，如分辨率为 (400, 500)
图像空间的大小为 256^{200000}

1. 存储空间无穷大，计算时间无穷。
2. 几乎每次遇到的状态下次都不会再遇到（泛化能力），需要泛化能力强

值函数的表示




采集到的数据:

$$Q(s, a) = \{q_1, q_2, \dots, q_n\}$$


如何得到其他状态行为值函数?

$$Q(s', a')$$



利用泛化方法得到其他状态行为处的值函数

值函数的表示



利用泛化方法得到其他状态行为处的值函数

基于函数逼近的强化学习：

强化学习+泛化方法

泛化方法：函数逼近理论，机器学习！

Remark: 不同的地方，非静态性，自举和延迟目标

利用函数逼近方法估计值函数 $\hat{q}(s, a; \theta)$

1. 参数化逼近

2. 非参数化逼近，如基于核的方法

参数化方法：

线性参数化：各种人为基底




非线性参数化：人工神经网络，决策树，模糊网络

值函数估计过程

Backup 值:

表格型值函数估计



$$\text{DP } Q_{\pi}(s, a) = R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a \sum_{a' \in A} \pi(a'|s') Q_{\pi}(s', a')$$




值函数估计过程

Backup 值:

$$\text{DP } Q_{\pi}(s, a) = R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a \sum_{a' \in A} \pi(a'|s') Q_{\pi}(s', a')$$



函数逼近: $\hat{q}(s, a, \theta)$




训练目标: $\arg \min_{\theta} \mathbb{E} (q(s, a) - \hat{q}(s, a, \theta))^2$

强化学习: 在线学习

值函数逼近的损失函数

函数逼近: $\hat{q}(s, a, \theta)$





训练目标: $\arg \min_{\theta} \mathbb{E} (q(s, a) - \hat{q}(s, a, \theta))^2$

强化学习: 在线学习

参数改变后, 其他状态值函数跟着也发生变化

非静态目标函数: 增量式学习方法和批方法



目标函数的构建:

$$\overline{VE}(w) = \sum_{s \in \mathcal{S}} \mu(s) [q_{\pi}(s, a) - \hat{q}(s, w)]^2$$


随机梯度下降

随机梯度下降法：

$$\theta_{t+1} = \theta_t + \alpha [U_t(s, a) - \hat{q}(s_t, a; \theta)] \nabla \hat{q}(s_t, a; \theta)$$

对于蒙特卡罗方法： $U_t(s) = G_t(s)$

给定策略 π 产生一次试验：



值函数估计过程：

监督学习，训练数据集为： $\langle s_1, G_1 \rangle, \langle s_2, G_2 \rangle, \dots$

策略评估过程为：

$$\Delta \theta = \alpha [U_t(s, a) - \hat{q}(s_t, a; \theta)] \nabla \hat{q}(s_t, a; \theta)$$

α 比较小，用来平衡不同状态值函数的误差

基于梯度的蒙特卡罗值函数评估算法

输入：要评估的策略 π ，一个可微逼近函数 $\hat{v}: S \times R^n \rightarrow R$

恰当地初始化的值函数权重 θ （例如 $\theta = 0$ ）

Repeat:

利用策略 π 产生一幕数据 $S_0, A_0, R_1, S_1, A_1, \dots, R_T, S_T$

for $t = 0, 1, \dots, T - 1$

$$\theta \leftarrow \theta + \alpha [G_t - \hat{q}(s_t, a; \theta)] \nabla \hat{q}(s_t, a; \theta)$$

半梯度下降

对于TD(0), DP等

$$U_t = R_{t+1} + \gamma \hat{q}(S_{t+1}, a; \theta) \quad \text{Bootstrapping}$$

半梯度方法:

$$\theta_{t+1} = \theta_t + \alpha [U_t(s, a) - \hat{q}(s_t, a; \theta)] \nabla \hat{q}(s_t, a; \theta)$$

$U_t(s)$ 依赖于当前的参数估计 θ

只考虑参数 θ 对估计值函数 $q(s_t, a; \theta_t)$ 的影响而忽略对目标函数 u_t 的影响, 称为半梯度法。

好处: 学习速度快, 可以应用到连续系统中

基于半梯度的TD(0)值函数评估算法

输入: 要评估的策略 π , 一个可微逼近函数 $\hat{v}: S \times R^n \rightarrow R$

恰当地初始化的值函数权重 θ (例如 $\theta = 0$)

Repeat:

初始化状态S,

Repeat (对于一幕中的每一步)


选择动作 $v(S_t, \theta_t)$

采用动作 A 并观测回报 R, S'

$$\theta \leftarrow \theta + \alpha [G_t - \hat{q}(s_t, a; \theta)] \nabla \hat{q}(s_t, a; \theta)$$

$$S \leftarrow S'$$

直到 S' 是终止状态



半梯度 Sarsa 算法

输入：一个要逼近的可微动作值函数： $\hat{q}: S \times A \times R^n \rightarrow R$ 任意地初始化的值函数权重 θ (例如 $\theta = 0$)

Repeat (for each episode) :

初始化状态行为对 S, A

Repeat (对于每一幕数据中的每一步) :

采用动作 A , 得到回报 R , 和下一个状态 S'

如果 S' 是终止状态:


进入下一幕

利用 **软策略** 选择一个动作 A' , 以便估计动作值函数 $\hat{q}(S', A', \theta)$

$$\theta \leftarrow \theta + \alpha [R + \gamma \hat{q}(S', A', \theta) - \hat{q}(S, A, \theta)] \nabla \hat{q}(S, A, \theta)$$

$$S \leftarrow S'$$

$$A \leftarrow A'$$



值函数的线性逼近

基于梯度或半梯度的值函数逼近:

$$\theta_{t+1} = \theta_t + \alpha [U_t(s) - \hat{q}(s_t, a; \theta_t)] \nabla \hat{q}(s_t, a; \theta_t)$$

线性逼近:

$$\hat{q}(s, a; \theta) = \theta^T \phi(s, a)$$

线性逼近的好处: 在线性情况, 仅有一个最优值, 因此可收敛到全局最优。

$\phi(s)$ 称为状态 s 的**特征函数**。

常用的基函数类型:

多项式基函数: $(1, s_1, s_2, s_1 s_2, s_1^2, s_2^2, \dots)$

傅里叶基函数: $\phi_i(s) = \cos(i\pi s), s \in [0, 1]$

径向基函数: $\phi_i(s) = \exp\left(-\frac{\|s - c_i\|^2}{2\sigma_i^2}\right)$

蒙特卡罗方法值函数更新:

$$\begin{aligned} \Delta\theta &= \alpha [U_t(s) - \hat{q}(s_t, a; \theta_t)] \nabla \hat{q}(s_t, a; \theta_t) \\ &= \alpha [G_t - \theta^T \phi] \phi \end{aligned}$$

TD(0) 线性逼近值函数更新为:


$$\begin{aligned} \Delta\theta &= \alpha [R + \gamma \theta^T \phi(s') - \theta^T \phi(s)] \phi(s) \\ &= \alpha \delta \phi(s) \end{aligned}$$

正向视角 $TD(\lambda)$

$$\Delta\theta = \alpha (G_t^\lambda - \theta^T \phi) \phi$$

反向视角 $TD(\lambda)$

$$\begin{aligned} \delta_t &= R_{t+1} + \gamma \theta^T \phi(s') - \theta^T \phi(s) \\ E_t &= \gamma \lambda E_{t-1} + \phi(s) \\ \Delta\theta &= \alpha \delta_t E_t \end{aligned}$$



批方法

增量式方法：计算简单，但往往存在样本效率不高的缺点。

批的方法寻找最好的拟合函数值 $\hat{q}(s, a; \theta)$ 。

给定经验数据集：

$$D = \{ \langle s_1, v_1^\pi \rangle, \langle s_2, v_2^\pi \rangle, \dots, \langle s_T, v_T^\pi \rangle \}$$

最小二乘方法：找到最优参数

$$LS(\theta) = \sum_{t=1}^T (q_t^\pi - \hat{q}(s_t, a; \theta))^2$$

$$= E_D [(q^\pi - \hat{q}(s, a; \theta))^2]$$

线性最小二乘逼近

$$\Delta\theta = \alpha \sum_{t=1}^T [q_t^\pi - \theta^T \phi(s_t, a)] \phi(s_t) = 0$$

最小二乘蒙特卡罗方法：

$$\text{LSMC: } \theta = \left(\sum_{t=1}^T \phi(s_t) \phi(s_t)^T \right)^{-1} \sum_{t=1}^T \phi(s_t) G_t$$

最小二乘时间差分方法：


LSTD:

$$\theta = \left(\sum_{t=1}^T \phi(s_t) (\phi(s_t) - \gamma \phi(s_{t+1}))^T \right)^{-1} \sum_{t=1}^T \phi(s_t) R_{t+1}$$

最小二乘TD(λ)方法：

LSTD (λ) :

$$\theta = \left(\sum_{t=1}^T E_t (\phi(s_t) - \gamma \phi(s_{t+1}))^T \right)^{-1} \sum_{t=1}^T E_t R_{t+1}$$



表格型强化学习是一种特殊的函数逼近

行为值函数表示：

$$Q(s, a) = \phi(s, a)^T \Theta$$

表格型值函数可以看成是函数逼近方法的一种特殊形式，每个格点表示一个特征。我们以鸳鸯系统为例，以表格的形式表示的行为-值函数共有 100×4 个元素，每个元素对应一个特征，则特征函数可以写为：

此时，参数 Θ 相应于原表格表示的行为值函数



固定稀疏表示

状态空间的维数为 n 维，即 $s = [s_1, \dots, s_n]$ ，每个维度离散化为 d 个数，则状态空间第 i 维

共有 d 个数，记为 v_i^j ，其中 $j = 1, \dots, d$ 。用固定稀疏来表示状态的特征为：


$$\phi(s) = [\phi_{11}, \phi_{12}, \dots, \phi_{1d}, \phi_{21}, \dots, \phi_{2d}, \dots, \phi_{n1}, \dots, \phi_{nd}]^T \quad (6.3)$$

状态-行为值函数的特征可表示为：

$$\phi(s, a) = [\phi^1(s), \dots, \phi^{|A|}(s)] \quad (6.5)$$

固定稀疏表示的特征的个数和参数的个数为： $d \times n \times |A|$ ，该表示特征的个数随维数线性增长而非指数增长。

函数逼近方法



前向神经网络的正向传播

神经网络可看成是基函数参数化的一种方法

$z_i^{(l)}$ 表示第 l 层第 i 个单元输入加权和

$$z_i^{(2)} = \sum_{j=1}^{n_1} W_{ij}^{(1)} x_j + b_i^{(1)}, \quad z_i^{(3)} = \sum_{j=1}^{n_2} W_{ij}^{(2)} x_j + b_i^{(2)}$$

$a_i^{(l)}$ 表示第 l 层的第 i 个单元激活, 则 $a_i^{(l)} = f(z_i^{(l)})$ 。

神经网络的前向计算为:

$$z^{(2)} = W^{(1)} x + b^{(1)}$$


$$a^{(2)} = f(z^{(2)})$$

$$z^{(3)} = W^{(2)} a^{(2)} + b^{(2)}$$

$$h_{W,b}(x) = a^{(3)} = f(z^{(3)})$$

参数化的基函数

输出层: $y = z^{(n_l)} = W^{(n_l-1)} a^{(n_l-1)} + b^{(n_l-1)}$



前向神经网络的结构

前向神经网络的后向传播

已知训练样本: $T = \{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(N)}, y^{(N)})\}$


优化函数为: $J(W, b; x^{(i)}, y^{(i)}) = \frac{1}{2} \|h_{W,b}(x^{(i)}) - y^{(i)}\|^2$

利用梯度下降法更新权值和偏置:

$$W_{ij}^{(l)} = W_{ij}^{(l)} - \alpha \frac{\partial}{\partial W_{ij}^{(l)}} J(W, b)$$

$$b_i^{(l)} = b_i^{(l)} - \alpha \frac{\partial}{\partial b_i^{(l)}} J(W, b)$$

关键是计算导数



前向神经网络的后向传播

Step1: 正向计算每层的输出

$$z^{(l+1)} = W^{(l)} a^{(l)} + b^{(l)}$$

$$a^{(l+1)} = f(z^{(l+1)})$$

Step2: 计算最后一层的残差


$$\delta_i^{(n_l)} = \frac{\partial}{\partial z_i^{n_l}} J(W, b; x, y) = \frac{\partial}{\partial z_i^{n_l}} \frac{1}{2} \|y - h_{W, b}(x)\|^2$$

$$= \frac{\partial}{\partial z_i^{n_l}} \frac{1}{2} \sum_{j=1}^{S_{n_l}} (y_j - f(z_j^{(n_l)}))^2$$

$$= - (y_i - a_i^{(n_l)}) \cdot f'(z_i^{(n_l)})$$

Step3: 残差从输出层往后逐渐传播

$$\delta_i^{(l)} = \left(\sum_{j=1}^{s_{l+1}} W_{ji}^{(l)} \delta_j^{(l+1)} \right) f'(z_i^{(l)})$$




前向神经网络的后向传播

Step3: 残差从输出层往后逐渐传播

$$\delta_i^{(l)} = \left(\sum_{j=1}^{s_{l+1}} W_{ji}^{(l)} \delta_j^{(l+1)} \right) f'(z_i^{(l)})$$

推导过程:

$$\begin{aligned} \delta_i^{(n_l-1)} &= \frac{\partial}{\partial z_i^{n_l-1}} J(W, b; x, y) = \frac{\partial}{\partial z_i^{n_l-1}} \frac{1}{2} \sum_{j=1}^{S_{n_l}} (y_j - a_j^{(n_l)})^2 \\ &= \frac{1}{2} \sum_{j=1}^{S_{n_l}} \frac{\partial}{\partial z_i^{n_l-1}} (y_j - f(z_j^{(n_l)}))^2 \\ &= \sum_{j=1}^{S_{n_l}} - (y_j - f(z_j^{(n_l)})) \cdot \frac{\partial}{\partial z_i^{(n_l-1)}} f(z_j^{(n_l)}) \\ &= \sum_{j=1}^{S_{n_l}} - (y_j - f(z_j^{(n_l)})) \cdot f'(z_j^{(n_l)}) \cdot \frac{\partial z_j^{(n_l)}}{\partial z_i^{(n_l-1)}} \end{aligned}$$



前向神经网络的后向传播


Step4: 计算偏导数

$$\frac{\partial}{\partial W_{ij}^{(l)}} J(W, b; x, y) = \frac{\partial}{\partial z_j^{(l+1)}} J(W, b; x, y) \cdot \frac{\partial z_j^{(l+1)}}{\partial W_{ij}^{(l)}}$$


最后的计算公式为:

$$\frac{\partial}{\partial W_{ij}^{(l)}} J(W, b; x, y) = a_i^{(l)} \delta_j^{(l+1)}$$

$$\frac{\partial}{\partial b_i^{(l)}} J(W, b; x, y) = \delta_i^{(l+1)}$$



卷积神经网络




LeNet 网络


卷积：权值共享，稀疏连接

池化：抽象特征表示，进一步减少权值

DQN 介绍



DQN网络



1. 框架为qlearning
2. 值函数表示为卷积神经网络

DQN 介绍

Qlearning伪代码

1. 初始化 $Q(s, a), \forall s \in S, a \in A(s)$, 给定参数 α, γ
2. Repeat:
3. 给定起始状态 s , 并根据 ϵ 贪婪策略在状态 s 选择动作 a
4. Repeat (对于一幕的每一步)
 - (a) 根据 ϵ 贪婪策略在状态 s_t 选择动作 a_t , 得到回报 r_t 和下一个状态 s_{t+1}

行动策略为 s_t 贪婪策略
 - (b) $Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha [r_t + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t)]$


目标策略为贪婪策略
 - (c) $s = s', a = a'$
5. Until s 是终止状态
6. Until 所有的 $Q(s, a)$ 收敛
7. 输出最终策略: $\pi(s) = \arg\max_a Q(s, a)$

DQN伪代码

- [1] Initialize replay memory D to capacity N
- [2] Initialize action-value function Q with random weights θ
- [3] Initialize target action-value function $\hat{Q}$ with weights $\theta^- = \theta$
- [4] For episode = 1, M do
- [5] Initialize sequence $s_1 = \{x_1\}$ and preprocessed sequence $\phi_1 = \phi(s_1)$
- [6] For $t = 1, T$ do
- [7] With probability ϵ select a random action a_t
- [8] otherwise select $a_t = \arg\max_a Q(\phi(s_t), a; \theta)$
- [9] Execute action a_t in emulator and observe reward r_t and image x_{t+1}
- [10] Set $s_{t+1} = s_t, a_t, x_{t+1}$ and preprocess $\phi_{t+1} = \phi(s_{t+1})$
- [11] Store transition $(\phi_t, a_t, r_t, \phi_{t+1})$ in D
- [12] Sample random minibatch of transitions $(\phi_j, a_j, r_j, \phi_{j+1})$ from D
- [13] Set $y_j = \begin{cases} r_j & \text{if episode terminates at step } j+1 \\ r_j + \gamma \max_{a'} \hat{Q}(\phi_{j+1}, a'; \theta^-) & \text{otherwise} \end{cases}$
- [14] Perform a gradient descent step on $(y_j - Q(\phi_j, a_j; \theta))^2$ with respect to the
- [15] network parameters θ
- [16] Every C steps reset $\hat{Q} = Q$
- [17] End For
- [18] End For

DQN 的技巧

(1) DQN利用卷积神经网络逼近行为值函数



(2) DQN利用经验回放对强化学习过程进行训练

$\langle s_1, a_1, r_2, s_2 \rangle$
$\langle s_2, a_2, r_3, s_3 \rangle$
$\langle s_3, a_3, r_4, s_4 \rangle$
$\langle s_4, a_4, r_5, s_5 \rangle$
$\langle s_5, a_5, r_6, s_6 \rangle$
$\vdots$

(3) DQN设置了目标网络来单独处理时间差分算法中的TD偏差。

$$\theta_{t+1} = \theta_t + \alpha \left[r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right] \nabla Q(s, a; \theta)$$

DQN变种 Double DQN

DQN设置了目标网络来单独处理时间差分算法中的TD偏差。

$$\theta_{t+1} = \theta_t + \alpha \left[r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right] \nabla Q(s, a; \theta)$$

目标网络为：

$$Y^{DQN} = r + \gamma \max_{a'} Q(s', a'; \theta^-)$$

Max操作会引入过优化问题

Double DQN:

$$Y^{DDQN} = r + \gamma Q\left(s', \arg \max_a Q(S_{t+1}, a; \theta_t); \theta^-\right)$$


两个值函数逼近网络，一个用来选择动作，一个用来评估值函数。

DQN利用经验回放对强化学习过程进行训练

$\langle s_1, a_1, r_2, s_2 \rangle$
$\langle s_2, a_2, r_3, s_3 \rangle$
$\langle s_3, a_3, r_4, s_4 \rangle$
$\langle s_4, a_4, r_5, s_5 \rangle$
$\langle s_5, a_5, r_6, s_6 \rangle$
$\vdots$

均匀采样到优先采样:

$$p_i \propto \delta_i$$



Dueling Network:

$$Q(s, a; \theta, \alpha, \beta) = V(s; \theta, \beta) + \left(A(s, a; \theta, \alpha) - \max_{a' \in |\mathcal{A}|} A(s, a'; \theta, \alpha) \right)$$

DQN变种 DRQN

Deep Recurrent Q-Network: Partial Observability

部分可观马尔科夫决策过程




Figure 2: DRQN convolves three times over a single-channel image of the game screen. The resulting activations are processed through time by an LSTM layer. The last two timesteps are shown here. LSTM outputs become Q-Values after passing through a fully-connected layer. Convolutional filters are depicted by rectangular sub-boxes with pointed tops.

Game	DRQN $\pm std$		DQN $\pm std$	
	Ours		Mnih et al.	
Asteroids	1020 (± 312)	1070 (± 345)	1629 (± 542)	
Beam Rider	3269 (± 1167)	6923 (± 1027)	6846 (± 1619)	
Bowling	62 (± 5.9)	72 (± 11)	42 (± 88)	
Centipede	3534 (± 1601)	3653 (± 1903)	8309 (± 5237)	
Chopper Cmd	2070 (± 875)	1460 (± 976)	6687 (± 2916)	
Double Dunk	-2 (± 7.8)	-10 (± 3.5)	-18.1 (± 2.6)	
Frostbite	2875 (± 535)	519 (± 363)	328.3 (± 250.5)	
Ice Hockey	-4.4 (± 1.6)	-3.5 (± 3.5)	-1.6 (± 2.5)	
Ms. Pacman	2048 (± 653)	2363 (± 735)	2311 (± 525)	

Table 1: On standard Atari games, DRQN performance parallels DQN, excelling in the games of Frostbite and Double Dunk, but struggling on Beam Rider. Bolded font indicates statistical significance between DRQN and our DQN.⁵

Deep Recurrent Q-Learning for Partially Observable MDPs

DQN变种 Rainbow

Parameter	Value
Min history to start learning	80K frames
Adam learning rate	0.0000625
Exploration ϵ	0.0
Noisy Nets σ_0	0.5
Target Network Period	32K frames
Adam ϵ	1.5×10^{-4}
Prioritization type	proportional
Prioritization exponent ω	0.5
Prioritization importance sampling β	0.4 $\rightarrow$ 1.0
Multi-step returns n	3
Distributional atoms	51
Distributional min/max values	$[-10, 10]$

Table 1: Rainbow hyper-parameters




Figure 1: **Median human-normalized performance** across 57 Atari games. We compare our integrated agent (rainbow-colored) to DQN (grey) and six published baselines. Note that we match DQN's best performance after 7M frames, surpass any baseline within 44M frames, and reach substantially improved final performance. Curves are smoothed with a moving average over 5 points.

Rainbow: Combining Improvements in Deep Reinforcement Learning



作业

1. 阅读《Reinforcement Learning: An Introduction》第6, 9章
2. 分组

