

# 强化学习原理第四讲：蒙特卡洛强化学习方法

人工智能学院

College of Artificial Intelligence




南开大学  
Nankai University

# 模型未知(model-free)

给定策略  $\pi$  构造值函数：

基于模型已知的DP方法



模型未知 ?

$$v_{\pi}(s) = \sum_{a \in A} \pi(a|s) \left( R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_{\pi}(s') \right)$$

当智能体采用策略  $\pi$  时，累积回报服从一个概率分布，累积回报在状态  $s$  处的期望值定义为值函数：

$$v_{\pi}(s) = E_{\pi}[G_t | S_t = s] = E_{\pi} \left[ \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s \right]$$

状态-行为值函数：

$$q_{\pi}(s, a) = E_{\pi} \left[ \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s, A_t = a \right]$$

蒙特卡洛方法利用经验平均代替随机变量的期望：

一次实验 (an episode) :  $S_1, A_1, R_2, \dots, S_k \sim \pi$

终止状态： 

计算状态  $s$  后的折扣回报返回值：

$$G_t = R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{T-1} R_T$$

# 蒙特卡洛策略评估

## 动态规划策略评估算法

输入：需要评估的策略  $\pi$  状态转移概率  $P_{ss'}^a$  回报函数  $R_s^a$ ，折扣因子  $\gamma$

初始化值函数：  $V(s) = 0$

Repeat  $k=0,1,\dots$

for every  $s$  do



$$v_{k+1}(s) = \sum_{a \in A} \pi(a|s) \left( R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_k(s') \right)$$

end for

Until  $v_{k+1} = v_k$

输出：  $v(s)$

一次状态扫描



⋮

蒙特卡罗方法利用 **经验平均** 代替随机变量的期望。

First visit MC策略评估：  $v(s) = \frac{G_{11}(s) + G_{21}(s) + \dots}{N(s)}$

every visit MC策略评估：

$$v(s) = \frac{G_{11}(s) + G_{12}(s) + \dots + G_{21}(s) + \dots}{N(s)}$$

根据大数定律：  $v(s) \rightarrow v_\pi(s) \text{ as } N(s) \rightarrow \infty$

**Remark:** 当只对一个点的值感兴趣，或者只对特定区域感兴趣时，蒙特卡洛方法效率很高

# 蒙特卡洛策略评估

## 动态规划策略评估算法

输入：需要评估的策略  $\pi$  状态转移概率  $P_{ss'}^a$  回报函数  $R_s^a$ ，折扣因子  $\gamma$

初始化值函数：  $V(s) = 0$

Repeat  $k=0,1,\dots$

for **every**  $s$  do



$$v_{k+1}(s) = \sum_{a \in A} \pi(a|s) \left( R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_k(s') \right)$$

end for

Until  $v_{k+1} = v_k$

输出：  $v(s)$

一次状态扫描



⋮

**First visit MC** and **every visit MC**

根据大数定律：  $v(s) \rightarrow v_\pi(s)$  as  $N(s) \rightarrow \infty$

**探索型初始化**状态：

每个状态都有一定的  
几率作为初始状态

|    |    |    |    |
|----|----|----|----|
|    | 1  | 2  | 3  |
| 4  | 5  | 6  | 7  |
| 8  | 9  | 10 | 11 |
| 12 | 13 | 14 |    |



# 蒙特卡洛评估—行为值函数



1. 对于模型未知的情况，最重要的是评估行为值函数


因为对于模型已知情况，状态值函数足矣

$$q_{\pi}(s, a) = R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_{\pi}(s')$$

2. 没有模型时，只有状态值就不够了，必须直接显式地评估： $q_{\pi}(s, a)$

行为值函数的定义： $q_{\pi}(s, a) = E_{\pi} \left[ \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s, A_t = a \right]$

蒙特卡洛策略评估：




$$\hat{q}(s, a) = \frac{G_{11}(s, a) + G_{12}(s, a) + \dots + G_{21}(s, a) + \dots}{N(s, a)}$$

根据大数定律：

$$\hat{q}(s, a) \rightarrow q_{\pi}(s, a) \text{ as } N(s, a) \rightarrow \infty$$

# 蒙特卡洛评估与动态规划评估的区别

1. 蒙特卡洛评估不需要用到bootstrap
2. 蒙特卡洛评估对单个状态的评估准确，不依赖其他状态评估是否准确，对于单个状态的估计**独立于状态空间大小**。



# 蒙特卡洛策略改进

蒙特卡洛策略改进:

对于每个状态 $s$ , 通过最大化动作值函数, 来进行策略的改进。

$$\pi(s) = \arg \max_a q(s, a)$$

我们需要评估当前状态下的每个动作的值函数


$$q_\pi(s, a) \text{ for } a \in A$$

需要访问所有的状态-行为对  $(s, a)$

行为值函数的定义:

$$q_\pi(s, a) = E_\pi \left[ \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s, A_t = a \right]$$

当前的策略:  $\pi(\cdot | \cdot) = 'e'$



$$q(s, a_1) \quad q(s, a_2) \quad q(s, a_3) \quad q(s, a_4)$$

# 蒙特卡洛强化学习：探索初始化

[1] 初始化所有：

$s \in S, a \in A(s), Q(s, a) \leftarrow \text{arbitrary},$   
 $\pi(s) \leftarrow \text{arbitrary}, \text{Returns}(s, a) \leftarrow \text{emptylist}$

[2] Repeat:

**随机选择**  $S_0 \in S, A_0 \in A(S_0)$  ，从  $S_0, A_0$  开始以策略  $\pi$

生成一个实验(episode)，对**每个**在这个实验中出现的状态和动作对(s,a):

[3]


$G \leftarrow s, a$ 第一次出现后的回报  
 将G附加于回报Returns(s, a)上  
 $Q(s, a) \leftarrow \text{average}(\text{Returns}(s, a))$ 对回报取均值

[4] 对该实验中的每一个s:

$\pi(s) \leftarrow \arg \max_a Q(s, a)$

策略评估

策略改进






# 蒙特卡洛强化学习：无探索初始化

- [1] 初始化所有：  
 $s \in S, a \in A(s), Q(s, a) \leftarrow \text{arbitrary},$   
 $\pi(s) \leftarrow \text{arbitrary}, \text{Returns}(s, a) \leftarrow \text{empty list}$
- [2] Repeat:  
**随机选择**  $S_0 \in S, A_0 \in A(S_0)$  , 从  $S_0, A_0$  开始以策略  $\pi$   
 生成一个实验 (episode), 对**每对**在这个实验中出现的  
 状态和动作, **s, a**:  

[3]  $G \leftarrow s, a$ 第一次出现后的回报  
 将G附加于回报Returns(s, a) 上  
 $Q(s, a) \leftarrow \text{average}(\text{Returns}(s, a))$ 对回报取均值

策略评估
- [4] 对该实验中的每一个s:  
 $\pi(s) \leftarrow \arg \max_a Q(s, a)$       策略改进

探索性初始化：迭代中每一幕的初始状态随机分配，以保证迭代过程中**每个状态行为对**都能被选中。假设所有的动作都被无限频繁选中。





# On-policy MC



策略必须是永久温和的，即对所有的s和a满足：  
 $\pi(a|s) > 0$

典型的策略为： $\epsilon$ -soft 策略，即

$$\pi(a|s) \leftarrow \begin{cases} 1 - \epsilon + \frac{\epsilon}{|A(s)|} & \text{if } a = \arg \max_a Q(s, a) \\ \frac{\epsilon}{|A(s)|} & \text{if } a \neq \arg \max_a Q(s, a) \end{cases}$$

所谓on-policy是指产生数据的策略与所评估和改善的策略是一个策略。

此处产生数据的策略和评估及改善的策略都是  
 $\epsilon$ -soft 策略

[1] 初始化所有： $s \in S, a \in A(s), Q(s, a) \leftarrow \text{arbitrary}$

$\text{Returns}(s, a) \leftarrow \text{empty list}$

$\pi(s) \leftarrow \text{arbitrary } \epsilon\text{-soft 策略,}$

**Repeat:**

[2] 从  $S_0, A_0$  开始以策略  $\pi$  生成一次实验 (episode),

[3] 对每对在这个实验中出现的状态和动作,  $s, a$ :

$G \leftarrow s, a$  第一次出现后的回报

将G附加于回报  $\text{Returns}(s, a)$  上

**策略评估**

$Q(s, a) \leftarrow \text{average}(\text{Returns}(s, a))$  对回报取均值

[4] 对该实验中的每一个  $s$ :

**策略改进**

$$\pi(a|s) \leftarrow \begin{cases} 1 - \epsilon + \frac{\epsilon}{|A(s)|} & \text{if } a = \arg \max_a Q(s, a) \\ \frac{\epsilon}{|A(s)|} & \text{if } a \neq \arg \max_a Q(s, a) \end{cases}$$



# off-policy MC

学习算法的困境：需要以最优的动作采样，但同时又需要探索所有的动作。

On-policy: 在探索和利用之间进行了妥协

对该实验中的每一个  $s$  :

$$\pi(a|s) \leftarrow \begin{cases} 1 - \epsilon + \frac{\epsilon}{|A(s)|} & \text{if } a = \arg \max_a Q(s, a) \\ \frac{\epsilon}{|A(s)|} & \text{if } a \neq \arg \max_a Q(s, a) \end{cases}$$

off-policy: 更直接的方法是利用两个策略，

一个是不断改进的策略（称为目标策略，target policy），


另外一个负责探索（称为动作策略，behavior policy），产生更多的动作



# off-policy MC

- 为了保证探索性，学习和评估的目标策略  $\pi$  与用来产生样本的行为策略  $\mu$  不同。根据行为策略  $\mu$  中获得的经验更新目标策略  $\pi$  的值。
- 例如：  $\pi$  是贪婪策略（最终的最优策略），  $\mu$  是探索策略（如  $\epsilon$ -soft 策略）
- Off-policy 的行为策略和目标策略需要满足覆盖性条件：即  $\mu$  产生的行为覆盖或包含  $\pi$  可能产生的行为，用式子表示即为：满足  $\pi(a|s) > 0$  的任何  $(s,a)$  均满足  $\mu(a|s) > 0$
- 重要性采样(importance sampling): 给每个回报赋以一定的权重，该权重为两个策略下轨迹可能性的比值

# 重要性采样



重要性采样

重要性采样求积分：

$$E[f] = \int f(z)p(z)dz$$

$$= \int f(z) \frac{p(z)}{q(z)} q(z) dz$$

$$\approx \frac{1}{N} \sum_n \frac{p(z^n)}{q(z^n)} f(z^n), z^n \sim q(z)$$

定义重要性权重： $\omega^n = p(z^n)/q(z^n)$

普通的重要性采样求积分： $E[f] = \frac{1}{N} \sum_n \omega^n f(z^n)$

重要性采样积分：无偏估计，但方差无穷大

减小方差的方法：加权重要性采样求积分

$$E[f] \approx \sum_{n=1}^N \frac{\omega^n}{\sum_{m=1}^N \omega^m} f(z^n)$$

在策略  $\pi$  下,  $t$  时刻后轨迹的概率为:

$$\Pr(A_t, S_{t+1}, \dots, S_T) = \prod_{k=t}^{T-1} \pi(A_k | S_k) p(S_{k+1} | S_k, A_k)$$

在目标策略和行为策略下, 每个回报都使用概率进行加权

$$\rho_t^T = \frac{\prod_{k=t}^{T-1} \pi(A_k | S_k) p(S_{k+1} | S_k, A_k)}{\prod_{k=t}^{T-1} \mu(A_k | S_k) p(S_{k+1} | S_k, A_k)} = \prod_{k=t}^{T-1} \frac{\pi(A_k | S_k)}{\mu(A_k | S_k)}$$

普通重要性采样, 值估计:

从  $t$  到  $T(t)$  的返回值

时间  $t$  后的第一次终止时刻

$$V(s) = \frac{\sum_{t \in T(s)} \rho_t^{T(t)} G_t}{|T(s)|}$$

状态  $s$  被访问过的所有时刻的集合

$s$  ■ ■ ■ ■

$t = 1 \ 2 \ 3 \ 4 \ 5 \ 6 \ 7 \ 8 \ 9 \ 10 \ 11 \ 12 \ 13 \ 14 \ 15 \ 16 \ 17 \ 18 \ 19$

$$T(s) = \{4, 15\} \quad T(4) = 7, T(15) = 19$$

加权重要性采样, 值估计:

$$V(s) = \frac{\sum_{t \in T(s)} \rho_t^{T(t)} G_t}{\sum_{t \in T(s)} \rho_t^{T(t)}}$$

# Off-policy every visit MC

初始化，对于所有的

$$s \in S, a \in A(s):$$

$$Q(s, a) \leftarrow \text{任意}$$

$$C(s, a) \leftarrow 0$$

$$\pi(s) \leftarrow \text{相对于 } Q \text{ 的贪婪策略}$$

Repeat forever:

利用软策略  $\mu$  产生一次实验:

$$S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T, S_T$$

$$G \leftarrow 0$$

$$W \leftarrow 1$$

For  $t = T-1, T-2, \dots$  down to 0:

$$G \leftarrow \gamma G + R_{t+1}$$

$$C(S_t, A_t) \leftarrow C(S_t, A_t) + W$$

策略评估


$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \frac{W}{C(S_t, A_t)} [G - Q(S_t, A_t)]$$

$$\pi(S_t) \leftarrow \arg \max_a Q(S_t, a)$$

策略改善

如果  $A_t \neq \pi(S_t)$  则退出for循环

$$W \leftarrow W \frac{1}{\mu(A_t | S_t)}$$





# 第四次作业



1. 阅读《Reinforcement Learning: An Introduction》第四章，并做读书笔记
2. 预习策略迭代，值迭代和MC算法代码

