

# 智能工程复习笔记

移动机器人运动学、感知与规划

2026 年 7 月 2 日

## 摘要

本笔记以课程 PDF 为准整理，按 PDF 分章：运动学建模（约束法与 ICR 法，大题）、里程计误差传导（通用雅可比形式，计算题）、最小二乘与点云到直线特征（RANSAC、霍夫变换）、SVD 与 ICP 点云配准、卡尔曼滤波、蒙特卡洛定位（MCL/AMCL）、建图算法与 SLAM（EKF-SLAM、FastSLAM、Graph-SLAM 重点含例题，简答为主）、运动规划（图搜索 A\*、DWA、TEB）。

## 目录

|                     |          |
|---------------------|----------|
| <b>1 运动学</b>        | <b>3</b> |
| 1.1 运动学模型的特点        | 3        |
| 1.2 车轮类型及约束         | 3        |
| 1.2.1 四种基本车轮        | 3        |
| 1.2.2 运动学约束前提假设     | 3        |
| 1.2.3 标准轮的两个约束      | 3        |
| 1.3 运动学建模方法之一：ICR 法 | 4        |
| 1.4 运动学建模方法之二：约束法   | 4        |
| 1.4.1 固定标准轮约束方程     | 5        |
| 1.4.2 转向标准轮约束方程     | 5        |
| 1.4.3 脚轮约束方程        | 5        |
| 1.4.4 麦克纳姆轮约束方程     | 5        |
| 1.4.5 约束法合成         | 6        |
| 1.5 建模例题            | 6        |
| 1.6 自由度分析           | 6        |
| 1.6.1 基本概念          | 7        |
| 1.6.2 五类轮式机器人       | 7        |
| <b>2 里程计模型</b>      | <b>7</b> |
| 2.1 由正运动学得到里程计      | 7        |
| 2.2 数值积分方法          | 8        |
| 2.3 误差传导模型（通用雅可比形式） | 8        |

|                                       |           |
|---------------------------------------|-----------|
| <b>3 最小二乘与点云到直线特征</b>                 | <b>9</b>  |
| 3.1 最小二乘 . . . . .                    | 9         |
| 3.2 2D 点云到直线特征 . . . . .              | 10        |
| <b>4 SVD 与 ICP 点云配准</b>               | <b>11</b> |
| 4.1 SVD（奇异值分解）用于点云配准 . . . . .        | 11        |
| 4.2 ICP 算法 . . . . .                  | 12        |
| <b>5 卡尔曼滤波</b>                        | <b>13</b> |
| 5.1 相关概念 . . . . .                    | 13        |
| 5.2 卡尔曼增益 . . . . .                   | 13        |
| 5.3 算法流程（Predict → Correct） . . . . . | 14        |
| 5.4 机器人定位中的应用 . . . . .               | 14        |
| <b>6 蒙特卡洛定位算法（MCL）</b>                | <b>14</b> |
| 6.1 蒙特卡洛方法基本思想 . . . . .              | 14        |
| 6.2 粒子滤波核心思想 . . . . .                | 14        |
| 6.3 蒙特卡洛定位算法 (MCL) . . . . .          | 15        |
| 6.4 激光雷达观测模型 . . . . .                | 15        |
| 6.5 MCL 算法总结 . . . . .                | 16        |
| 6.6 自适应蒙特卡洛定位算法（AMCL） . . . . .       | 16        |
| <b>7 建图算法与 SLAM</b>                   | <b>17</b> |
| 7.1 地图表示方法 . . . . .                  | 17        |
| 7.2 SLAM 基本思想 . . . . .               | 17        |
| 7.3 EKF-SLAM . . . . .                | 18        |
| 7.4 FastSLAM . . . . .                | 19        |
| 7.5 Graph-SLAM（重点，考计算题） . . . . .     | 20        |
| <b>8 运动规划</b>                         | <b>23</b> |
| 8.1 运动规划分类 . . . . .                  | 23        |

## 第一章 运动学

### 核心要点

本章重点：运动模型构建。两种建模方法——ICR 法与约束法，主要考大题（给定机器人结构，用两种方法建立运动学方程）。

### 1.1 运动学模型的特点

- 运动学模型构建机器人驱动（输入）与空间位姿（输出）间的关系。
- 与机械臂区别：机械臂本体坐标系固定（精度高）；移动机器人本体坐标系随运动变化（精度低），无法从位置空间找到一一对应关系。
- 采用微分运动学（速度空间映射）替代位置空间映射。
- 运动学模型是机械结构设计、控制器设计、环境感知的基础，与车轮密切相关。

### 1.2 车轮类型及约束

#### 1.2.1 四种基本车轮

| 类型             | 自由度               | 约束数      | 特点                                      |
|----------------|-------------------|----------|-----------------------------------------|
| 标准轮 (Standard) | 2: 滚动 + 转动        | 1: 沿轮轴滑动 | 高指向性；分固定轮（1 自由度）与转向轮（2 自由度）             |
| 脚轮 (Castor)    | 3: 滚动 + 转动 + 沿轴运动 | 0        | 偏心距 $d$ ；常作随动轮；调向时施加扭矩                  |
| 瑞典轮 (Swedish)  | 3                 | 0 (全向轮)  | 无法单独使用，至少 3 个；麦克纳姆轮 $\gamma = 45^\circ$ |
| 球轮 (Spherical) | 3                 | 0        | 真正全向轮；成本高、可靠性差，极少使用                     |

#### 1.2.2 运动学约束前提假设

- 在水平面上运动；车轮与地面点接触；车轮不变形。
- 纯滚动：接触点无滑动速度（无滑动、打滑）。
- 舵机转轴与地面垂直；轮子安装在刚体表面上。

#### 1.2.3 标准轮的两个约束

1. 滚动约束：沿轮平面方向的运动约束（主动轮需考虑）。
2. 滑动约束：沿轮轴方向无运动（主动轮与随动标准轮均需考虑）。

**注意**

不论滚动约束还是滑动约束，只考虑**独立约束**。平面运动输出状态为三维向量，最多有 3 个独立约束。

### 1.3 运动学建模方法之一：ICR 法

#### 原理

**核心要点**

- 移动机器人可视为刚体：每个点相对距离不变——各点角速度相同。
- 固定标准轮沿轮轴方向运动约束 ( $\dot{y}_R = 0$ )。
- 所有轮轴延长线交于**瞬时旋转中心 ICR** (Instantaneous Center of Rotation)。
- 设 ICR 到机器人坐标系原点距离为  $R$ ，轮子中心距原点为  $l$ ，可解得速度。

#### 建模步骤

1. 确定系统输入（轮速  $\dot{\varphi}$ 、舵机转角  $\beta$ ）。
2. 确定惯性参考坐标系  $I$  与机器人参考坐标系  $R$ ，确定输出。
3. 构建坐标系间变换关系： $\dot{\xi}_R = R(\theta)\dot{\xi}_I$ 。
4. 利用刚体角速度相同 + 轮轴滑动约束确定 ICR 位置。
5. 由 ICR 几何关系求机器人速度。

#### 优缺点

- **优点：**比较直观；对标准轮建模容易。
- **缺点：**一事一议，不具备通用性；仅适用于标准轮建模。

#### 双轮差速机器人 ICR 法建模

设两轮半径为  $r$ ，轮距机器人中心为  $l$ ，轮速  $\dot{\varphi}_L, \dot{\varphi}_R$ 。由 ICR 法可得：

**关键公式**

$$v = \frac{r(\dot{\varphi}_R + \dot{\varphi}_L)}{2}, \quad \omega = \frac{r(\dot{\varphi}_R - \dot{\varphi}_L)}{2l}$$

世界坐标系下运动学模型：

$$\dot{x} = v \cos \theta, \quad \dot{y} = v \sin \theta, \quad \dot{\theta} = \omega$$

### 1.4 运动学建模方法之二：约束法

## 原理

对每个车轮分别建立滚动约束方程与滑动约束方程，合成构成机器人整体运动学约束。适用于所有轮型，具有通用性。

### 1.4.1 固定标准轮约束方程

设轮的位置角  $\alpha$ （轮心在机器人坐标系中的极角）、转向角  $\beta$ （轮平面与机器人坐标系  $x_R$  轴夹角）、轮心到原点距离  $l$ 、轮半径  $r$ 。

#### 关键公式

滚动约束（沿轮平面纯滚动）：

$$\begin{bmatrix} \sin(\alpha + \beta) & -\cos(\alpha + \beta) & -l \cos \beta \end{bmatrix} \dot{\xi}_I = r \dot{\varphi}$$

滑动约束（沿轮轴无运动）：

$$\begin{bmatrix} \cos(\alpha + \beta) & \sin(\alpha + \beta) & l \sin \beta \end{bmatrix} \dot{\xi}_I = 0$$

其中  $\dot{\xi}_I = [\dot{x}, \dot{y}, \dot{\theta}]^T$  为世界坐标系下速度。

### 1.4.2 转向标准轮约束方程

与固定标准轮形式相同，但  $\beta = \beta(t)$  是时变变量（舵机转角）。

### 1.4.3 脚轮约束方程

由于偏心距  $d$  的存在，连杆相对于惯性系的角速度为  $\dot{\theta}_R + \dot{\beta}$ ，约束方程中需考虑偏心距  $d$  的影响。脚轮可通过控制垂直旋转轴角速度  $\dot{\beta}$  实现全方位运动；随动脚轮不给机器人带来运动约束（全向运动轮）。

### 1.4.4 麦克纳姆轮约束方程

设辊子角度  $\gamma$ （ $\gamma = 0$  为 90 度瑞典轮， $\gamma = 45^\circ$  为麦克纳姆轮）：

#### 关键公式

滚动约束：

$$\begin{bmatrix} \sin(\alpha + \beta + \gamma) & -\cos(\alpha + \beta + \gamma) & -l \sin(\beta + \gamma) \end{bmatrix} R(\theta) \dot{\xi}_I - r \dot{\varphi} \sin \gamma - r_{sw} \dot{\varphi}_{sw} = 0$$

滑动约束：

$$\begin{bmatrix} \cos(\alpha + \beta + \gamma) & \sin(\alpha + \beta + \gamma) & l \cos(\beta + \gamma) \end{bmatrix} R(\theta) \dot{\xi}_I - r \dot{\varphi} \cos \gamma = 0$$

麦克纳姆轮为全向轮，当作为随动轮时可不考虑运动约束。

### 1.4.5 约束法合成

#### 核心要点

给定机器人含  $M$  个车轮，每个车轮提供 0 个或多个约束：

- 驱动轮：同时考虑滚动和滑动约束。
- 随动轮：仅考虑滑动约束（只有标准轮作为随动轮时需考虑）。
- 滚动约束方程与滑动约束方程融合，可得机器人整体运动学约束。

### 1.5 建模例题

#### 双轮差速机器人约束法建模

轮  $A$  沿  $X_R$  轴正方向， $\alpha_A = -\pi/2$ ,  $\beta_A = \pi$ ；轮  $B$  沿  $X_R$  轴正方向， $\alpha_B = \pi/2$ ,  $\beta_B = 0$ 。  
滚动约束（代入公式）：

$$\begin{cases} \text{轮 } A: [-1, 0, 0] R(\theta) \dot{\xi}_I = r \dot{\varphi}_A \\ \text{轮 } B: [1, 0, 0] R(\theta) \dot{\xi}_I = r \dot{\varphi}_B \end{cases}$$

滑动约束（两轮共线，仅一个独立约束）：

$$[0, 1, 0] R(\theta) \dot{\xi}_I = 0 \implies \dot{y}_R = 0$$

联立解得： $v = \frac{r(\dot{\varphi}_A + \dot{\varphi}_B)}{2}$ ,  $\omega = \frac{r(\dot{\varphi}_B - \dot{\varphi}_A)}{2l}$ 。

#### 叉车式机器人（两种方法对比）

叉车有 3 个轮子：2 个随动固定标准轮（轮  $A$ 、轮  $B$ ,  $L_1 = 1$ ），1 个主动转向标准轮（轮  $P$ ,  $L_2 = 2$ ,  $\beta_0 = \pi/2$ ,  $\beta$  为舵机转角）。

**ICR 法：**由随动轮滑动约束得  $\dot{y}_R = 0$ ，ICR 在  $y_R$  轴上。 $R = L_2 / \cos \beta$ ，解得：

$$\dot{\theta}_R = -\frac{r\dot{\varphi}}{L_2} \cos \beta, \quad \dot{\xi}_R = \dot{x}_R = r\dot{\varphi} \sin \beta$$

**约束法：**

- 主动轮滚动约束： $\dot{x}_R \sin \beta - \dot{y}_R \cos \beta - \dot{\theta}_R L_2 \cos \beta = r\dot{\varphi}$
- 主动轮滑动约束： $\dot{x}_R \cos \beta + \dot{y}_R \sin \beta + \dot{\theta}_R L_2 \sin \beta = 0$
- 随动轮滑动约束： $\dot{y}_R = 0$

联立解得与 ICR 法相同结果。

### 1.6 自由度分析

### 1.6.1 基本概念

- 移动度  $\delta_m$  (瞬时自由度): 衡量瞬时改变运行方向的能力。

$$\delta_m = 3 - \text{rank}(C_1(q))$$

$C_1(q)$  的秩越大, 约束越多, 瞬时改变方向能力越弱。

- 转向度  $\delta_s$  (附加自由度): 独立的能够转向的舵机个数,  $0 \leq \delta_s \leq 2$ 。
- 机动度  $\delta_M$  (综合自由度):  $\delta_M = \delta_m + \delta_s$ 。

#### 注意

- 机动度相同的机器人, 结构不一定相同。
- $\delta_M = 2$  的机器人, 其 ICR 必位于一条直线上。
- $\delta_M = 3$  的机器人, 其 ICR 可分布于空间中任意一点。
- 机动度描述的是综合能力, 不是瞬时能力。

### 1.6.2 五类轮式机器人

| $(\delta_m, \delta_s)$ | 名称            | 代表示例                          |
|------------------------|---------------|-------------------------------|
| (3,0)                  | 完整约束全方位移动机器人  | CMU 单球机器人、NKOMNI 脚轮机器人、麦克轮排渣车 |
| (2,1)                  | 非完整约束全方位移动机器人 | 舵机 + 脚轮/瑞典轮, 横向平移稳定性差         |
| (1,2)                  | 非完整约束全方位移动机器人 | 深圳普智联科停车机器人                   |
| (2,0)                  | 非完整约束移动机器人    | KIVA 双轮差速车、先锋机器人              |
| (1,1)                  | 非完整约束移动机器人    | 自动牵引车、叉车、玉兔号月球车、机遇号火星车        |

## 第二章 里程计模型

### 核心要点

本章考计算题: 里程计积分 + 误差传导 (通用雅可比形式)。

### 2.1 由正运动学得到里程计

里程计模型由正运动学得到, 核心是对路程  $\Delta s$  和角度  $\Delta \theta$  做数值积分。

$$\Delta s = \frac{r}{2}(\Delta \phi_R + \Delta \phi_L), \quad \Delta \theta = \frac{r}{2d}(\Delta \phi_R - \Delta \phi_L)$$

## 2.2 数值积分方法

给定码盘读数  $\Delta s, \Delta\theta$  ( $v_k T_s = \Delta s$ ,  $\omega_k T_s = \Delta\theta$ ):

### 1. 欧拉法

$$\begin{cases} x_{k+1} = x_k + \Delta s \cos \theta_k \\ y_{k+1} = y_k + \Delta s \sin \theta_k \\ \theta_{k+1} = \theta_k + \Delta\theta \end{cases}$$

### 2. 解析积分法

$$\begin{cases} x_{k+1} = x_k + \frac{\Delta s}{\Delta\theta} (\sin \theta_{k+1} - \sin \theta_k) \\ y_{k+1} = y_k - \frac{\Delta s}{\Delta\theta} (\cos \theta_{k+1} - \cos \theta_k) \\ \theta_{k+1} = \theta_k + \Delta\theta \end{cases}$$

( $\Delta\theta = 0$  时退化为直线)

### 3. 二阶 Runge-Kutta 法 (最常用)

$$\begin{cases} x_{k+1} = x_k + \Delta s \cos\left(\theta_k + \frac{\Delta\theta}{2}\right) \\ y_{k+1} = y_k + \Delta s \sin\left(\theta_k + \frac{\Delta\theta}{2}\right) \\ \theta_{k+1} = \theta_k + \Delta\theta \end{cases}$$

## 2.3 误差传导模型 (通用雅可比形式)

### 核心要点

核心公式 (计算题重点):

$$\Sigma_{k+1} = F_p \Sigma_k F_p^T + F_\Delta \Sigma_\Delta F_\Delta^T$$

- $F_p = \frac{\partial f}{\partial p}$ : 运动模型对位姿的雅可比。
- $F_\Delta = \frac{\partial f}{\partial \Delta}$ : 运动模型对输入 (码盘读数) 的雅可比。
- $\Sigma_k$ : 当前位姿估计的协方差;  $\Sigma_\Delta$ : 输入误差协方差。



## 输入误差建模

假设左右轮误差独立，方差正比于转过的距离绝对值：

$$\Sigma_{\Delta} = \text{covar}(\Delta\phi_R, \Delta\phi_L) = \begin{bmatrix} k_r |\Delta\phi_R| & 0 \\ 0 & k_l |\Delta\phi_L| \end{bmatrix}$$

## 雅可比矩阵（二阶 RK 法下）

运动模型  $p_{k+1} = f(p_k, \Delta_k)$ ，其中  $p_k = (x_k, y_k, \theta_k)^T$ ， $\Delta_k = (\Delta\phi_R, \Delta\phi_L)^T$ 。

位姿雅可比  $F_p$ ：

$$F_p = \frac{\partial f}{\partial p} = \begin{bmatrix} 1 & 0 & -\Delta s \sin\left(\theta_k + \frac{\Delta\theta}{2}\right) \\ 0 & 1 & \Delta s \cos\left(\theta_k + \frac{\Delta\theta}{2}\right) \\ 0 & 0 & 1 \end{bmatrix}$$

输入雅可比  $F_{\Delta}$ ：

$$F_{\Delta} = \frac{\partial f}{\partial \Delta} = \begin{bmatrix} \frac{\partial x}{\partial \Delta\phi_R} & \frac{\partial x}{\partial \Delta\phi_L} \\ \frac{\partial y}{\partial \Delta\phi_R} & \frac{\partial y}{\partial \Delta\phi_L} \\ \frac{\partial \theta}{\partial \Delta\phi_R} & \frac{\partial \theta}{\partial \Delta\phi_L} \end{bmatrix}$$

其中利用  $\Delta s = \frac{r}{2}(\Delta\phi_R + \Delta\phi_L)$ ， $\Delta\theta = \frac{r}{2d}(\Delta\phi_R - \Delta\phi_L)$  求偏导。

## 误差传导特性

- 直线运动：垂直于运动方向的误差增长快于运动方向。
- 曲线运动：误差椭圆不再保持垂直于运动方向。
- 系统误差标定：单向/双向正方形路径实验。

## 第三章 最小二乘与点云到直线特征

### 核心要点

本章对应 PDF 《激光传感器定位原理》，包含最小二乘法与从点云提取直线特征两部分。

### 3.1 最小二乘

#### 注意

最小二乘法假设最佳拟合曲线使给定数据集的偏差平方和最小。本课程不要求重点掌握。

## 数学表达

设数据点  $(x_i, y_i)$ ，拟合曲线  $f(x)$ ，偏差  $d_i = y_i - f(x_i)$ ：

$$\Pi = \sum_{i=1}^n d_i^2 = \sum_{i=1}^n [y_i - f(x_i)]^2 = \min$$

## 矩阵形式与最优解

回归模型  $Y = X\beta + \epsilon$ ，残差平方和  $S(\beta) = (Y - X\beta)^T(Y - X\beta)$ ：

$$\beta = (X^T X)^{-1} X^T Y$$

## 3.2 2D 点云到直线特征

### 动机

数据压缩、信息丰富、高级特征基础、环境适应性（直线段适用于办公室类环境）。

### 三个主要问题

1. 有多少条线？
2. 分割：哪些点属于哪条线？
3. 直线拟合：给定属于一条线的点，如何估计直线参数？

### 常用算法

- **Split-and-merge**（分割与合并）：递归拟合与分割， $O(N \log N)$ ，确定性强。
- **Linear regression**（线性回归）：滑动窗口拟合。
- **RANSAC**（随机采样一致性）：**重点**，鲁棒，适用于存在离群点的情况。
- **Hough-Transform**（霍夫变换）：点对参数空间投票。

### RANSAC 算法步骤

1. 随机选取 2 个点作为样本。
2. 计算拟合该样本的模型参数。
3. 计算每个数据点的误差。
4. 选择支持当前假设的数据（内点）。
5. 重复采样，取  $k$  次迭代后内点数最多的集合。

### RANSAC 迭代次数

设  $w$  为内点比例， $p$  为选取无离群点最小集合的概率：

$$k = \frac{\log(1-p)}{\log(1-w^2)}$$

**注意**

迭代次数  $k$  与点数  $N$  无关，仅与内点比例  $w$  有关。例： $p = 99\%$ ,  $w = 50\%$  时  $k = 16$  次。

**霍夫变换**

- 图像空间一条直线对应 Hough 空间一个点。
- 图像空间一点映射到 Hough 空间一条曲线（极坐标下为正弦曲线）。
- 极坐标表示： $\rho = x \cos \theta + y \sin \theta$ 。

**算法比较**

| 方法              | 复杂度              | 速度 (Hz) | 误检率 | 精度   |
|-----------------|------------------|---------|-----|------|
| Split-and-Merge | $N \log N$       | 1500    | 10% | +++  |
| Incremental     | $SN$             | 600     | 6%  | +++  |
| Line-Regression | $NN_f$           | 400     | 10% | +++  |
| RANSAC          | $SNk$            | 30      | 30% | ++++ |
| Hough-Transform | $SNN_C + SNRN_C$ | 10      | 30% | ++++ |

**加权最小二乘直线拟合**

每个传感器测量具有不确定性  $\sigma^2$ ，加权平方误差：

$$S = \sum_i w_i d_i^2 = \sum_i w_i (\rho_i \cos(\theta_i - \alpha) - r)^2, \quad w_i = \frac{1}{\sigma_i^2}$$

点到直线距离  $d_i = \rho_i \cos(\theta_i - \alpha) - r$ 。

**第四章 SVD 与 ICP 点云配准****核心要点**

本章对应 PDF 《SVD 算法与 ICP 算法》。需要掌握 SVD 的分解思想与算法步骤。SVD 要会写，ICP 也要会写，但不考推导。

**4.1 SVD（奇异值分解）用于点云配准****问题描述**

给定两个对应点集  $P = \{p_1, \dots, p_n\}$ ,  $Q = \{q_1, \dots, q_n\}$ ，求刚体变换  $(R, t)$ ：

$$(R, t) = \arg \min_{R, t} \sum_{i=1}^n w_i \| (Rp_i + t) - q_i \|^2$$

## SVD 求解步骤

1. 加权平均:  $\hat{p} = \frac{\sum w_i p_i}{\sum w_i}$ ,  $\hat{q} = \frac{\sum w_i q_i}{\sum w_i}$ , 其中  $w_i = 1/\sigma_i(\rho_i)$ 。
2. 去中心化:  $x_i := p_i - \hat{p}$ ,  $y_i := q_i - \hat{q}$ 。
3. 构造 SVD 矩阵:  $W = \text{diag}(w_1, \dots, w_n)$ ,  $S = XWY^T = U\Sigma V^T$ 。
4. 求旋转矩阵:  $R = VU^T$ 。
5. 求平移矩阵:  $t = \hat{q} - R\hat{p}$ 。

## 4.2 ICP 算法

### 核心要点

ICP (Iterative Closest Point) 用于在数据关联未知的情况下, 估计两组点云之间的位姿变换。要会流程、流程图与匹配过程。

### 基本流程

1. 计算最近点集: 对源点云  $P$  中每个点  $p_i$ , 在目标点云  $X$  中找最近点  $y_i$ 。
2. 计算变换矩阵: 用 SVD 求解  $(R, t)$ 。
3. 更新变换矩阵: 应用变换到源点云。
4. 计算目标函数并进行阈值判断: 若未收敛则迭代。

### 最近点集定义

$$d(\vec{p}_i, X) = \min_{\vec{x} \in X} \|\vec{x} - \vec{p}_i\|, \quad Y = C(P, X) = \{(\vec{p}_i, \vec{y}_i) \mid d(\vec{p}_i, \vec{y}_i) = d(\vec{p}_i, X)\}$$

### 点云采样 (数据预处理)

- 目的: 减少计算量、降低噪声干扰、避免冗余与局部过拟合、加速迭代收敛。
- 常见方法: 均匀采样、随机采样、法向量空间采样、基于特征的采样、体素网格采样。

### 点集匹配方法

- **Closest Point Matching:** 稳定但慢, 需预处理。
- **Normal Shooting Matching:** 沿法线方向投影求交; 对平滑结构略优。
- **Point-to-Plane Matching:** 求源曲面点到目标曲面切平面的垂足。
- **Projection Matching:** 沿投影线求交; 速度快 1 ~ 2 个数量级。

### Point-to-Point 与 Point-to-Distribution

- Point-to-Point 采用欧氏距离:  $\hat{R} = \arg \max_R \sum w_i \|(Rp_i + t) - q_i\|^2$ 。

- Point-to-Distribution 采用马氏距离：

$$\hat{T} = \arg \max_T \sum_{i=1}^n d_i^\top (\Sigma_b + T \Sigma_a T^\top)^{-1} d_i$$

### 注意

#### ICP 总结：

- ICP 是计算不同扫描结果之间位移关系的强大算法。
- 主要难点在于正确确定数据关联关系。
- 一旦数据关联正确，变换矩阵可通过 SVD 高效求解。

## 第五章 卡尔曼滤波

### 核心要点

不考推导与公式。核心思想：测量能看到的和实际看到的存在偏差；根据先验误差与观测误差确定增益  $K$ 。先验误差越大，通常取较大的  $K$ 。

### 5.1 相关概念

- 先验状态估计  $\hat{x}_k^-$ ：基于过程转移方程和第  $k$  步之前的状态得出。
- 先验估计误差： $e_k^- \equiv x_k - \hat{x}_k^-$ ，协方差  $P_k^- = E[e_k^- e_k^{-T}]$ 。
- 后验状态估计  $\hat{x}_k$ ：结合测量值  $z_k$  和先验估计。
- 后验估计误差： $e_k \equiv x_k - \hat{x}_k$ ，协方差  $P_k = E[e_k e_k^T]$ 。

### 5.2 卡尔曼增益

后验状态估计为先验估计与测量新息的加权线性组合：

$$\hat{x}_k = \hat{x}_k^- + K(z_k - H\hat{x}_k^-)$$

目标函数  $\arg \min_K P_k$ ，对  $K$  求导令其为零：

$$K = P_k^- H^T (H P_k^- H^T + R)^{-1}$$

### 注意

#### 极限情况：

- $R \rightarrow 0$  时， $K \rightarrow H^{-1}$ （完全相信测量）。
- $P_k^- \rightarrow 0$  时， $K \rightarrow 0$ （完全相信先验）。

### 5.3 算法流程 (Predict → Correct)

#### Predict (预测步)

$$\bar{x}_k^- = A\bar{x}_{k-1}, \quad P_k^- = AP_{k-1}A^T + Q$$

#### Correct (修正步)

$$K = P_k^- H^T (HP_k^- H^T + R)^{-1}$$

$$\bar{x}_k = \bar{x}_k^- + K(\bar{z}_k - H\bar{x}_k^-), \quad P_k = (I - KH)P_{k-1}^-$$

### 5.4 机器人定位中的应用

- **Action update:** 通过本体感受传感器估计位置，不确定性**增长**。
- **Perception update:** 使用外感受传感器观测，不确定性**缩小**。

#### 注意

基于卡尔曼滤波定位算法总结：

- 仅能处理**位置跟踪**问题，无法进行全局定位。
- 可融合里程计与激光（精度可达 5mm），但严重依赖匹配精度。
- 匹配错误则定位失败，且无法判断失败、无法从失败中恢复。
- 收敛速度受初始状态误差与协方差阵精度影响较大。

## 第六章 蒙特卡洛定位算法 (MCL)

### 6.1 蒙特卡洛方法基本思想

#### 核心要点

- **工作原理:** 不断抽样 → 逐渐逼近。
- **优点:** 非常通用，可解决十分复杂的问题。
- **缺点:** 收敛速度慢，不精确。
- **应用实例:** 蒙特卡洛搜索树——AlphaGo。

### 6.2 粒子滤波核心思想

任意概率分布都可以通过样本（粒子 Particle）分布来描述。某一区间样本越多，对应发生概率越高。可有效处理非高斯分布以及各种复杂分布。

## 未知概率分布求取粒子分布——基于重要性的重采样

### 关键公式

核心思想：使用提议分布  $g$  (proposal) 生成来自目标分布  $f$  (target) 的样本。重要性权重  $w = f/g$ 。

重采样步骤：

1. 重要性评估：计算重要性指标  $\omega = f/g$ 。
2. 权重归一化： $\bar{\omega}_i = \frac{\omega_i^{fg}}{\sum_{i=1}^N \omega_i^{fg}}$ 。
3. 重采样：利用更新后的概率分布进行重采样，得到新的粒子集。

## 6.3 蒙特卡洛定位算法 (MCL)

### 目标与输入输出

- 目标：给定环境地图，确定机器人在环境中的位姿。
- 输入：上一时刻信念  $X_{t-1}$ 、执行指令  $u_t$ 、传感器数据  $z_t$ 。
- 输出：新的信念  $X_t$ 。

### 算法流程

1. 初始化：从  $X_{t-1}$  的分布开始。
2. 预测步：基于运动模型更新并采样。
3. 修正步：通过传感器模型计算权重（重要性评估）。
4. 重采样：基于归一化权重进行重采样（幸运转盘）。
5. 输出：获得  $X_t$  的分布。

## 6.4 激光雷达观测模型

### 物理模型（基于光束的物理反射特性）

- 测量误差包含随机噪声，一般服从高斯分布。
- 没有检测到障碍物时返回最大测距距离。
- 随机错误时返回错误的距离值。

### Likelihood Field（似然场）

- 将激光束末端投影到地图中。
- 计算投影点距离地图上最近障碍物点的距离。
- 以最近障碍物点为均值，激光测距偏差为方差构建高斯分布。

**注意**

似然场优点：在线计算量小、平滑性好可确保算法收敛、更加符合实际情况。

似然场缺点：没有明确的物理意义；仅适用于相对静态的环境。

## 6.5 MCL 算法总结

**注意**

优点：

- 可解决大范围全局定位问题。
- 可适用于多种分布模型。
- 计算简单。

缺点：

- 粒子数量过大时占用大量内存，计算效率低。
- 位置确定后大量粒子冗余；但大地图下少量粒子又易导致发散。
- 无法判断机器人绑架问题（定位错误问题）。

## 6.6 自适应蒙特卡洛定位算法（AMCL）

**核心要点**

自适应体现（核心思想是长程滤波器与短程滤波器）：

- 解决机器人绑架问题：当粒子平均分数突然降低时，在全局重新撒入随机粒子。
- 解决粒子数固定问题：当粒子集中时（定位已收敛），减少粒子数量以提高效率。

### KLD 采样

采用 KLD（Kullback-Leibler Divergence）确定粒子数量。

- 核心思想：根据基于采样近似质量的统计界限确定粒子数量。以概率  $1 - \sigma$  确保真实后验概率与采样近似分布之间差异小于  $\epsilon$ 。
- 实际应用：在栅格地图中统计粒子占据的栅格数。占据栅格多（粒子分散），允许粒子数上限高；占据栅格少（粒子集中），降低上限。

### AMCL 权重评估机制

- 引入长期指数滤波器衰减率  $\alpha_{slow}$  和短期指数滤波器衰减率  $\alpha_{fast}$ （ROS 默认取 0.001 和 0.1）。
- 机器人绑架/定位错误：粒子平均权重  $w_{avg}$  下降，导致  $w_{slow} > w_{fast}$ ，按一定概率注入随机粒子。
- 粒子聚集/定位成功：  $w_{slow} < w_{fast}$ ，不再添加随机粒子，筛选权重较大的粒子。



## 第七章 建图算法与 SLAM

### 核心要点

本章重点考简答，详细介绍每个算法的原理核心思想、步骤、优缺点。Graph-SLAM 保留例题，考计算题。

### 7.1 地图表示方法

| 类型             | 特点                                        | 应用/备注                                      |
|----------------|-------------------------------------------|--------------------------------------------|
| 点云地图           | 完全表示环境三维信息；不需预定义尺寸                        | 存储要求高；存在检测盲区和空洞；通用性差                       |
| 栅格地图           | 离散栅格，每个栅格有占用属性值；定位用 $0 \sim 1$ 概率，导航用 0/1 | 用二元贝叶斯滤波求解；几率对数形式 $l = \log \frac{p}{1-p}$ |
| 2.5 维占用栅格      | 在栅格上增加障碍物高度属性                             | 典型应用：NASA 火星车；可能存在虚拟障碍物问题                  |
| 三维占用栅格 (Voxel) | 空间分解为大小相同的正方体                             | 原理简单，扩展性强；占用大量存储空间                         |
| 多分辨率地图         | 常采用八叉树表示                                  | 存储效率高                                      |
| 特征地图           | 连续线性/多边形地图                                | 空间占用效率高；定位精度高                              |
| 拓扑地图           | 节点表示重要位置点，边表示连接关系                         | 难以用于精确定位，但便于导航和路径规划                        |

### 栅格地图构建——二元贝叶斯滤波

几率对数形式 ( $l = \log \frac{p}{1-p}$ )，每次激光测量独立：

$$l_{i,n} = \log \frac{p(m_i | s_n)}{p(\bar{m}_i | s_n)} + l_0 + l_{i,n-1}$$

若栅格占用情况未知， $p = 0.5 \Rightarrow l_0 = 0$ 。

### 7.2 SLAM 基本思想

- **定位**：根据环境地图和机器人运动/观测序列，确定机器人在地图中的位置和姿态（前提：地图已知）。
- **建图**：根据观测序列和机器人位姿，确定环境信息（前提：机器人位姿已知）。
- **SLAM**：同时估计机器人位置和姿态以及环境地图。”先有鸡还是先有蛋”问题。
- **数据关联**是 SLAM 实现收敛的关键，错误匹配会使算法发散。
- **闭环检测**：机器人回到以前到过的地方，与之前观测建立正确数据关联，可有效降低估计不确定性。

## SLAM 算法分类

- 基于滤波：EKF-SLAM（卡尔曼滤波）、FastSLAM（粒子滤波）——GMAPPING。
- 基于优化：基于图优化的 SLAM——g2o，目前主流。

## 7.3 EKF-SLAM

### 原理核心思想

#### 核心要点

- 第一个 SLAM 算法（1986 年），面向特征地图（路标特征地图）。
- 采用最大似然（maximum likelihood）进行数据关联。
- 假设特征彼此清晰可分，运动和观测噪声满足高斯分布。
- 以机器人初始位姿为地图坐标系原点。
- 与 EKF 机器人定位类似，但维度大大增加：待估计状态  $x_t \in \mathbb{R}^{3+2N}$ 。

### 状态向量与协方差矩阵

$$x_t = \begin{bmatrix} X_R \\ M_1 \\ M_2 \\ \vdots \\ M_n \end{bmatrix}, \quad \Sigma_t = \begin{bmatrix} \Sigma_{X_R} & \Sigma_{X_R m_1} & \cdots & \Sigma_{X_R m_n} \\ \Sigma_{m_1 X_R} & \Sigma_{m_1} & \cdots & \Sigma_{m_1 m_n} \\ \vdots & \vdots & \ddots & \vdots \\ \Sigma_{m_n X_R} & \Sigma_{m_n m_1} & \cdots & \Sigma_{m_n} \end{bmatrix}$$

### 算法步骤

1. **State Prediction**（状态预测）：基于运动模型进行状态估计。
2. **Measurement Prediction**（观测预测）：基于观测模型进行观测预测。
3. **Observation**（观测）：获得本次观测。
4. **Data Association**（数据关联）：建立预估观测与本次观测的数据关联。
5. **Update**（更新）：利用 Kalman 增益进行状态更新。
6. **Integration of new landmark**（新路标加入）：在地图中加入新的路标。

### 优缺点

#### 注意

优点：多变量高斯函数表达机器人位姿和路标估计；高斯协方差矩阵体现高度互相关性。

#### EKF 致命缺点：

- 计算复杂度高（quadratic complexity）：协方差矩阵  $(2N + 3) \times (2N + 3)$ ，观测到一个路标整个协方差矩阵被更新，大场景难以满足实时性。

- 数据关联 (single-hypothesis): 单假设数据关联, 即使小部分错误关联也会导致算法发散。
- 仅适用于人工路标情况; 只能用点云/特征地图, 无法使用栅格地图。

## 7.4 FastSLAM

### 原理核心思想

#### 核心要点

- Montemerlo 等人提出 (2003 年), 是粒子滤波器与 EKF 的集成。
- 机器人路径估计: 用改进的粒子滤波器估计机器人路径的后验分布, 每个粒子代表一条可能运动路径。
- 路标估计: 路标用 EKF 估计, 每个粒子拥有  $N$  个 EKF (2 维)。
- 条件独立性: 在机器人路径已知的情况下, 路标位置的估计相对独立。

### Rao-Blackwell 定理 (RBPF 降维)

利用变量间依赖关系进行因式分解, 将 SLAM 后验概率分解:

$$p(x_{0:t}, l_{1:M} | z_{1:t}, u_{1:t}) = \underbrace{p(x_{0:t} | z_{1:t}, u_{1:t})}_{\text{粒子滤波 (路径)}} \prod_{i=1}^M \underbrace{p(l_i | x_{0:t}, z_{1:t}, u_{1:t})}_{\text{2 维 EKF (路标)}}$$

- 粒子维度从  $3t + 2N$  维降至 3 维 (机器人位姿)。
- 每个粒子维护  $M$  个独立的 2 维 EKF。

### 算法步骤

1. 运动更新: 基于采样 (粒子) 的机器人位姿表示, 每个粒子作为一条完整路径假设。
2. 数据关联与观测更新: 观测特征与地图特征匹配 (多假设分析)。
3. 基于 EKF 的地图更新: 每个粒子用 EKF 更新路标位置。
4. 基于观测的权重计算: 根据卡尔曼滤波的估计方差对粒子重要性进行评估。
5. 基于权重的重采样。

### 优缺点

#### 注意

#### 优点:

- 利用 RBPF 降维, 提升算法效率。
- 基于随机采样的数据关联具有更高的鲁棒性 (相较于 EKF 最重要的优势)。
- 利用多假设分析可在数据关联时忽略机器人位姿误差的影响。
- 应用实例: GMapping。

缺点：粒子数量选取影响内存利用率；粒子枯竭会导致定位与建图错误。

## 7.5 Graph-SLAM（重点，考计算题）

原理核心思想

### 核心要点

- 基于优化思想，利用图论描述 SLAM 问题。
- 节点：机器人位姿  $x_i = (x, y, \theta)$ ；或特征/路标  $m_i = (x, y)$ 。
  - 仅含位姿节点：Pose Graph。
  - 含特征节点：Pose-feature Graph。
- 边：节点间的空间约束（里程计测量、观测/虚拟测量）。
- 信息矩阵  $\Omega_{ij}$ ：描述两节点间约束的不确定性。值越大，节点相关性越高，优化中越应重视。
- 图优化 SLAM：构建图（前端），寻求最优节点构型使得约束误差最小（后端优化）。

### 算法构成

- 前端（图的构建）：构建节点与边。
- 后端（图优化）：基于构建的图和约束关系，修正节点位姿以最大程度满足空间约束。

### 后端优化目标函数

$$\vec{x}^* = \arg \min_{\vec{x}} \sum_{ij} \vec{e}_{ij}^T \Omega_{ij} \vec{e}_{ij}$$

- Pose Graph 误差： $e_{ij}(\vec{x}_i, \vec{x}_j) = t2v(Z_{ij}^{-1}(X_i^{-1}X_j))$ 。
- Pose-feature Graph 误差： $e_{ij}(z_i, \vec{x}_j) = \hat{z}_{ij} - z_{ij} = R_j^{-1}(z_i - t_j) - z_{ij}$ 。

### 高斯-牛顿法求解

对误差函数在当前估计处泰勒展开： $e_k(\tilde{x}_k + \Delta x) \approx e_k + J_k \Delta x$ ：

$$\vec{b} = \sum_k J_k^T \Omega_k \vec{e}_k, \quad H = \sum_k J_k^T \Omega_k J_k$$

$$\Delta \vec{x} = -H^{-1} \vec{b}$$

### 稀疏性

- $H$  矩阵为稀疏矩阵，对边  $x_i x_j$  的约束仅影响  $H$  的  $(i, i), (i, j), (j, i), (j, j)$  处数据块。
- 可利用稀疏矩阵求解算法：Sparse Cholesky decomposition、Conjugate gradients（共轭梯度法）。

$H_k$  非满秩时的处理

- 增加约束：固定一个节点（一般固定  $\vec{x}_i$ ）。
- **Simplified Levenberg-Marquardt**:  $(H_k + \lambda I)\Delta\vec{x} = -\vec{b}_k$ 。

## 优缺点

## 注意

## 优点：

- 仅将实际发生关联的约束构建连接进行优化，效率大大提升。
- 优化思想取代概率思想，算法容易理解、便于计算。
- 常用库：g2o、Karto、Carter。

## 例题 1: Pose Graph (计算题)

## 例题

机器人初始起点  $x_0 = 0$ ，向前移动编码器测得移动 1 m 到达  $x_1$ ，又向后返回编码器测得移动  $-0.8$  m 到达  $x_2$ 。通过闭环检测发现回到原始起点 ( $x_2 \rightarrow x_0$  虚拟测量为 0)。求机器人位姿最优状态。

节点:  $x_0, x_1, x_2$ 。 边:  $(x_0x_1) \rightarrow 1, (x_1x_2) \rightarrow -0.8, (x_2x_0) \rightarrow 0, x_0 \rightarrow 0$ 。

定义误差函数：

$$f_1 = x_0, \quad f_2 = x_1 - x_0 - 1, \quad f_3 = x_2 - x_1 + 0.8, \quad f_4 = x_2 - x_0$$

目标函数：

$$c = \sum_{i=1}^4 f_i^2 = x_0^2 + (x_1 - x_0 - 1)^2 + (x_2 - x_1 + 0.8)^2 + (x_2 - x_0)^2$$

对各变量求偏导令其为零：

$$\begin{bmatrix} 3 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.0 \\ 1.8 \\ -0.8 \end{bmatrix}$$

求解：

$$\mu = \begin{bmatrix} 0 \\ 0.93 \\ 0.07 \end{bmatrix}$$

即  $x_0 = 0, x_1 = 0.93 \text{ m}, x_2 = 0.07 \text{ m}$ 。

## 例题 2: Pose Feature Graph (计算题)

## 例题

机器人初始起点  $x_0 = 0$ ，观测到正前方 2 m 处有路标  $l_0$ 。向前移动编码器测得移动 1 m 到  $x_1$ ，观测到路标在前方 0.8 m。求机器人位姿和路标位姿最优状态。

节点:  $x_0, x_1, l_0$ 。 边:  $(x_0 l_0) \rightarrow 2, (x_0 x_1) \rightarrow 1, (x_1 l_0) \rightarrow 0.8, x_0 \rightarrow 0$ 。

误差函数:

$$f_1 = l_0 - x_0 - 2, \quad f_2 = x_1 - x_0 - 1, \quad f_3 = l_0 - x_1 - 0.8, \quad f_4 = x_0$$

目标函数:

$$c = (l_0 - x_0 - 2)^2 + (x_1 - x_0 - 1)^2 + (l_0 - x_1 - 0.8)^2 + x_0^2$$

求偏导令其为零:

$$\begin{bmatrix} 3 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ l_0 \end{bmatrix} = \begin{bmatrix} 3.0 \\ 0.2 \\ 2.8 \end{bmatrix}$$

求解:

$$\mu = \begin{bmatrix} 0 \\ 1.07 \\ 1.93 \end{bmatrix}$$

即  $x_0 = 0, x_1 = 1.07 \text{ m}, l_0 = 1.93 \text{ m}$ 。

## 例题 3: 带信息矩阵的优化 (计算题)

## 例题

机器人初始起点  $x_0 = 0$ ，向前移动编码器测得移动 0.8 m 到  $x_1$ 。此时观测到与初始状态相同的环境信息，虚拟测量  $z_{12} = 1$ ，方差为 0.4。求机器人位姿最优状态。

信息矩阵:  $\Omega_{12} = 1/0.4 = 2.5$ 。

计算误差:  $e_{12} = z_{12} - (x_1 - x_0) = 1 - 0.8 = 0.2$ 。

计算雅可比:  $J_{12} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$  (对  $x_0, x_1$ )。

更新系数矩阵:

$$H_{12} = J_{12}^T \Omega_{12} J_{12} = 2.5 \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}, \quad b_{12} = e_{12} \Omega_{12} J_{12} = \begin{bmatrix} 0.5 \\ -0.5 \end{bmatrix}$$

固定  $x_0$  增加约束 ( $H$  非满秩):

$$H = H_{12} + \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 3.5 & -2.5 \\ -2.5 & 2.5 \end{bmatrix}$$

求解：

$$\Delta x = -H^{-1}b = \begin{bmatrix} 0 \\ 0.2 \end{bmatrix}, \quad x_{\text{new}} = \begin{bmatrix} 0 \\ 0.8 \end{bmatrix} + \begin{bmatrix} 0 \\ 0.2 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

即  $x_0 = 0$ ,  $x_1 = 1 \text{ m}$ 。

## SLAM 算法对比总结

| 算法         | 核心思想                      | 优点               | 缺点                                  |
|------------|---------------------------|------------------|-------------------------------------|
| EKF-SLAM   | 卡尔曼滤波，高斯假设                | 第一个 SLAM 算法，理论成熟 | 计算复杂度高 $O(N^2)$ ；单假设数据关联易发散；仅适用特征地图 |
| FastSLAM   | RBPF 降维：粒子滤波估路径 + EKF 估路标 | 鲁棒性强；多假设数据关联；效率高 | 粒子枯竭；粒子数选取影响性能                      |
| Graph-SLAM | 图优化：节点为位姿，边为约束            | 效率高；易于理解；仅优化关联约束 | 依赖前端图构建质量                           |

## 第八章 运动规划

### 核心要点

本章对应 PDF 《第六章移动机器人运动规划技术》。重点：图搜索算法（A\*）、局部规划（DWA、TEB）的核心思想与优缺点。

### 8.1 运动规划分类

- **路径规划**：只考虑工作空间（环境）的几何约束，不考虑机器人和执行器约束。
  - 基于图搜索的路径规划算法（**算法完备**，复杂度大）。
  - 基于采样的路径规划算法（**概率完备**，速度快但可能“有解求不出”）。
- **轨迹规划**：在给定路径上考虑机器人和执行器约束生成随时间变化的运动序列。

### 图的构建

- **可视图（Visibility Graph）**：可实现无碰撞的最短距离规划，但太过靠近障碍物。
- **维诺图（Voronoi Graph）**：路径距离周围两个最近障碍物距离相等，最大化与障碍物距离，最为安全。
- **栅格地图**：将空间分解为离散栅格。

### 图搜索算法对比

**DFS（深度优先搜索）**：以深度为优先级，使用栈结构。完备但不最优，无方向性效率低。

**BFS（宽度优先搜索）：**以广度为优先级，使用 FIFO 队列。完备但不最优，无方向性效率低。

**Dijkstra 算法：**基于 BFS，使用优先队列每次选代价最小节点。完备且最优，但效率低（地图信息利用不充分）。

**A\* 算法：**在 Dijkstra 基础上结合目标进行搜索，启发式算法（目标牵引）。

#### 关键公式

$$f(n) = g(n) + h(n)$$

- $g(n)$ ：从出发点到当前节点的路径代价。
- $h(n)$ ：当前节点到目标节点的路径代价估计（启发函数）。

**启发函数：**曼哈顿距离  $|x_1 - x_2| + |y_1 - y_2|$ ；欧几里得距离  $\sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$ ；切比雪夫距离  $\max(|x_1 - x_2|, |y_1 - y_2|)$ 。

$h(n) = 0$  时退化为 Dijkstra 算法。

**权重 A\*：** $f(n) = g(n) + \epsilon \cdot h(n)$  ( $\epsilon \geq 1$ )。权重增加提高速度，但不满足可采纳性，只能得到局部最优解。

**ARA\* 算法：** $\epsilon$  先取较大值（如 2.5）快速得到路径，再不断降低  $\epsilon$  至 1 优化路径；引入 INCONS 表减少重复计算。

#### 基于采样的路径规划

- **PRM（概率路线图）：**多查询，离线构建 roadmap，在线查询。
- **RRT（快速随机探索树）：**单查询，从起点向随机采样点扩展，概率完备。

#### 局部路径规划——DWA（Dynamic Window Approach）

##### 核心要点

**核心思想：**控制空间采样。由 Fox、Burgard、Thrun 于 1997 年提出。

- 假设  $(v, \omega)$  在固定  $\Delta t$  内恒定，每条局部路径为圆弧段。
- **速度采样考虑：**机器人速度约束、执行器能力约束、环境约束（可接受 admissible：能在碰到障碍物前停下来）。
- **评价函数（归一化后加权求优）：**方向角评价、空隙（距障碍物距离）、速度大小。

##### 注意

##### DWA 优缺点：

- **优点：**快速根据环境信息反应；有效避免碰撞；计算复杂度低、对硬件要求低；实用性高。
- **缺点：**可能得不到全局最优解；局部最优可能使机器人陷入死锁；可预见性差，门口



位置速度过快。

### 局部路径规划——TEB (Timed Elastic Band)

#### 核心要点

**核心思想：**基于优化思想。由 Roesmann 等人于 2012 年提出。连接起始、目标点，让路径变形，将所有约束当作橡皮筋的外力。

- **Elastic-Band:** 起始/目标点状态由用户指定，中间插入  $N$  个控制点（机器人位姿）。
- **Timed-Elastic-Band:** 为控制点赋予时间。
- 通过加权多目标优化获取最优路径点  $B$ 。
- 约束目标函数组成：
  1. 跟随路径和避障约束 ( $d_{\min,j}$ ,  $r_{p\max}$ ,  $r_{o\max}$ )。
  2. 速度和加速度约束。
  3. Non-holonomic 运动学约束（两轮差速机器人）。
  4. 最小时间约束。
- **优化特性：**每个目标函数只与 elastic band 中某几个连续状态有关， $J$  为稀疏矩阵（约 15% 非零元素）；目标函数梯度可视为对 elastic band 施加的外力。